

TRƯỜNG ĐẠI HỌC TRÀ VINH
KHOA KỸ THUẬT VÀ CÔNG NGHỆ



ISO 9001:2015

LÊ THANH TRUYỀN

PHÁT HIỆN BẤT THƯỜNG TRONG ẢNH Y KHOA

ĐỒ ÁN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ THÔNG TIN

TRÀ VINH, NĂM 2024

TRƯỜNG ĐẠI HỌC TRÀ VINH
KHOA KỸ THUẬT VÀ CÔNG NGHỆ

PHÁT HIỆN BẤT THƯỜNG TRONG ẢNH Y KHOA

**ĐỒ ÁN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ THÔNG TIN**

Sinh viên: **Lê Thanh Truyền**

Lớp: **DA20TTB**

MSSV: **110120163**

GVHD: **ThS. Nguyễn Mộng Hiền**

TRÀ VINH, NĂM 2024

LỜI MỞ ĐẦU

Bước vào thế kỷ 21, công nghệ thông tin đã trở thành trụ cột trong hầu hết mọi lĩnh vực trọng điểm như giao thông và vận tải, sản xuất công nghiệp, dịch vụ, tài chính, giáo dục,... và trở thành một phần không thể thiếu trong cuộc sống hàng ngày, đem lại những thành tựu đáng kể và cải thiện lớn cho đời sống xã hội. Trong đó, sự phát triển vượt bậc của trí tuệ nhân tạo và học máy đã thúc đẩy sự tiến bộ đáng kể trong mọi lĩnh vực, từ sản xuất công nghiệp đến dịch vụ tài chính. Đặc biệt, trong lĩnh vực y học, y học ngày càng phát triển nhờ vào sự tiến bộ vượt bậc của công nghệ. Nổi bật là sức mạnh của trí tuệ nhân tạo đang được khai thác mạnh mẽ để nâng cao khả năng chẩn đoán và điều trị bệnh. Trí tuệ nhân tạo và học sâu đang đóng vai trò quan trọng trong việc phát hiện các bất thường trong ảnh y khoa, giúp nâng cao hiệu quả chẩn đoán, điều trị và giảm thiểu rủi ro cho bệnh nhân. Khả năng của trí tuệ nhân tạo trong việc xử lý và phân tích dữ liệu lớn, kết hợp với khả năng học và tự điều chỉnh, đã tạo ra những tiềm năng mới trong việc cải thiện chăm sóc sức khỏe và cứu sống bệnh nhân.

Khóa luận này tập trung nghiên cứu và ứng dụng các mô hình học sâu vào việc phát hiện bất thường trong ảnh y khoa. Nội dung của khóa luận gồm các chương: Chương 1 giới thiệu về các khái niệm cơ bản và bối cảnh nghiên cứu. Chương 2 giới thiệu một số mô hình học sâu phổ biến. Chương 3 mô tả việc hiện thực hoá nghiên cứu, áp dụng các mô hình vào thực nghiệm trên tập dữ liệu cùng với các phương pháp đánh giá và huấn luyện chúng. Chương 4 là phân kết luận, đánh giá công việc đã thực hiện trong chương 3. Cuối cùng, chương 5 tổng kết những gì đã đạt được và đề xuất những hướng phát triển tiếp theo.

Em hy vọng rằng khóa luận này sẽ đóng góp một phần nhỏ vào việc nâng cao hiệu quả chẩn đoán y khoa bằng cách ứng dụng các công nghệ tiên tiến, đồng thời mở ra những hướng nghiên cứu mới trong lĩnh vực này. Bằng cách tận dụng sức mạnh của trí tuệ nhân tạo và học máy, con người có thể hy vọng vào một tương lai với các phương pháp chẩn đoán và điều trị tiên tiến hơn, mang lại lợi ích to lớn cho xã hội.

LỜI CẢM ƠN

Em xin chân thành cảm ơn các thầy cô trong Bộ môn Công nghệ Thông tin, Khoa Kỹ thuật và Công nghệ Trường Đại học Trà Vinh, đã truyền đạt kiến thức và hỗ trợ em trong suốt quá trình học tập và nghiên cứu thực hiện khoá luận này.

Đặc biệt, em xin gửi lời cảm ơn sâu sắc đến Thầy Nguyễn Mộng Hiền, người giảng viên hướng dẫn kiên nhẫn và tận tình đã hỗ trợ em hoàn thành khoá luận. Những góp ý quý báu và sự hỗ trợ nhiệt tình của thầy đã giúp em vượt qua những khó khăn và hoàn thiện công việc nghiên cứu của mình.

Em cũng xin cảm ơn các anh chị và bạn bè đã luôn bên cạnh, động viên và giúp đỡ em trong suốt quá trình học tập và thực hiện khoá luận. Những lời động viên và sự hỗ trợ từ các bạn đã giúp em có thêm động lực để hoàn thành tốt.

Cuối cùng, em xin gửi lời cảm ơn đến gia đình, là nguồn động viên to lớn và là chỗ dựa vững chắc cho em. Sự ủng hộ và tình yêu thương của gia đình đã giúp em vượt qua mọi thử thách và đạt được kết quả như ngày hôm nay.

Em xin trân trọng cảm ơn!

Trà Vinh, ngày tháng ... năm 2024

Sinh viên thực hiện

Lê Thanh Truyền

This image shows a full page of a document template designed for handwritten notes or answers. It features approximately 28 evenly spaced horizontal dotted lines across the entire width of the page, providing a guide for letter height and placement. The background is plain white, and there are no margins, headers, or footers visible.

Giảng viên hướng dẫn
(ký và ghi rõ họ tên)

BẢN NHẬN XÉT ĐỒ ÁN, KHÓA LUẬN TỐT NGHIỆP
(Của giảng viên hướng dẫn)

Họ và tên sinh viên: Lê Thanh Truyền

MSSV: 110120163

Ngành: Công nghệ Thông tin

Khóa: 2020

Tên đề tài: Phát hiện bất thường trong ảnh y khoa

Họ và tên Giáo viên hướng dẫn: Nguyễn Mộng Hiền

Chức danh: Giảng viên

Học vị: Thạc sĩ

NHẬN XÉT

1. Nội dung đề tài:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

2. Ưu điểm:

.....

.....

.....

3. Khuyết điểm:

.....

.....

.....

.....

4. Điểm mới đề tài:

.....

.....
.....
.....
.....
5. Giá trị thực trên đề tài:

.....
.....
.....
.....
.....
.....
.....
7. Đề nghị sửa chữa bổ sung:

.....
.....
.....
.....
8. Đánh giá:

.....
.....
.....
.....
Trà Vinh, ngày tháng năm 2024
Giảng viên hướng dẫn
(Ký & ghi rõ họ tên)

MỤC LỤC

CHƯƠNG 1. ĐẶT VẤN ĐỀ	1
1.1. Lý do chọn đề tài.....	1
1.2. Mục tiêu	1
1.3. Nội dung.....	1
1.4. Đối tượng và phạm vi nghiên cứu	2
1.5. Phương pháp nghiên cứu	2
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	3
2.1. Sơ lược về học sâu	3
2.1.1. Định nghĩa.....	3
2.1.2. Ứng dụng	3
2.1.3. Cấu tạo chung của một mô hình học sâu	3
2.1.4. Các bước hoạt động của một mô hình học sâu	4
2.2. Các mô hình học sâu	5
2.2.1. Mạng CNN.....	5
2.2.2. Mạng RNN.....	7
2.2.3. Mạng Autoencoder	8
2.2.4. Mạng GAN.....	9
2.2.5. Mạng ResNet	10
2.2.6. Mạng DenseNet	11
2.3. Quy trình huấn luyện và đánh giá một mô hình học sâu	12
CHƯƠNG 3. HIỆN THỰC HÓA NGHIÊN CỨU	14
3.1. Mô tả bài toán	14
3.2. Những kết quả đã đạt được trước đó	14
3.3. Đề xuất cách giải quyết bài toán	15
3.4. Giới thiệu tập dữ liệu	15
3.5. Môi trường cài đặt.....	16
CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU	17
4.1. Chuẩn bị thư viện và dữ liệu.....	17
4.2. Xây dựng các mô hình	19
4.2.1. Mô hình CNN	19
4.2.2. Mô hình ResNet	21
4.2.3. Mô hình DenseNet.....	23
4.3. Huấn luyện các mô hình	25
4.4. Đánh giá các mô hình	25
4.5. Xây dựng giao diện phát hiện bất thường trong ảnh	35

4.6. Nhận xét.....	37
4.7. Hướng dẫn sử dụng ứng dụng.....	37
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	41
5.1. Kết luận.....	41
5.2. Hướng phát triển	41
DANH MỤC TÀI LIỆU THAM KHẢO.....	42

DANH MỤC CÁC BẢNG, SƠ ĐỒ, HÌNH

Hình 1. Cấu tạo chung một mô hình học sâu [5].....	4
Hình 2. Cấu tạo chung của mạng CNN [8]	6
Hình 3. Cấu tạo chung của một mạng RNN [9]	7
Hình 4. Cấu tạo của ba mạng RNN, LSTM và GRU [11]	8
Hình 5. Cấu tạo của mạng Autoencoder [13]	9
Hình 6. Cấu tạo của mạng GAN [14]	10
Hình 7. Cấu tạo của một biến thể ResNet – ResNet18 [15].....	11
Hình 8. Cấu tạo của mạng DenseNet [17]	12
Hình 9. Cây thư mục của tập dữ liệu	16
Hình 10. Các thư viện cho việc xây dựng các mô hình.....	17
Hình 11. Các thư viện dùng cho việc sắp xếp dữ liệu	17
Hình 12. Các biến dựa trên cấu trúc của tập dữ liệu	18
Hình 13. Số lượng hình ảnh trong từng thư mục.....	18
Hình 14. Thực hiện việc xáo trộn và phân chia hình ảnh theo tỷ lệ.....	19
Hình 15. Kiểm tra lại số lượng hình ảnh sau khi chia	19
Hình 16. Sơ đồ khối kiến trúc CNN được đề xuất	20
Hình 17. Mã nguồn kiến trúc mô hình CNN	21
Hình 18. Sơ đồ khối kiến trúc chung của ResNet50	21
Hình 19. Sơ đồ khối mô hình ResNet được đề xuất	22
Hình 20. Mã nguồn kiến trúc mô hình ResNet	22
Hình 21. Sơ đồ khối kiến trúc chung của DenseNet121	23
Hình 22. Sơ đồ khối mô hình DenseNet được đề xuất	24
Hình 23. Mã nguồn kiến trúc mô hình DenseNet	24
Hình 24. Chỉ số độ chính xác trên tập kiểm thử của mô hình CNN	25
Hình 25. Chỉ số độ chính xác trên tập kiểm thử của mô hình ResNet.....	25
Hình 26. Chỉ số độ chính xác trên tập kiểm thử của mô hình DenseNet.....	26
Hình 27. Hàm vẽ biểu đồ thể hiện độ chính xác khi huấn luyện của các mô hình	26
Hình 28. Biểu đồ thể hiện độ chính xác khi huấn luyện mô hình CNN	27
Hình 29. Biểu đồ thể hiện độ mất mát khi huấn luyện mô hình CNN	27
Hình 30. Biểu đồ thể hiện độ chính xác khi huấn luyện mô hình ResNet	28
Hình 31. Biểu đồ thể hiện độ mất mát khi huấn luyện mô hình ResNet	29

Hình 32. Biểu đồ thể hiện độ chính xác khi huấn luyện mô hình DenseNet	29
Hình 33. Biểu đồ thể hiện độ mất mát khi huấn luyện mô hình DenseNet	30
Hình 34. Ma trận nhầm lẫn [22]	31
Hình 35. Ma trận nhầm lẫn của mô hình CNN	32
Hình 36. Ma trận nhầm lẫn của mô hình ResNet	33
Hình 37. Ma trận nhầm lẫn của mô hình DenseNet	34
Hình 38. Các thư mục của hệ thống	35
Hình 39. Giao diện chính	36
Hình 40. Kết quả hiển thị ảnh bình thường	36
Hình 41. Kết quả hiển thị ảnh bất thường	37
Hình 42. Vị trí tệp Python cần tải	38
Hình 43. Cấu trúc thư mục của ứng dụng	38
Hình 44. Kích hoạt môi trường ảo	38
Hình 45. Thông báo chạy giao diện ứng dụng	39
Hình 46. Giao diện ứng dụng trên trình duyệt	39
Hình 47. Chọn tệp hình ảnh cần thử	39
Hình 48. Kết quả sau khi tải hình ảnh lên	40
Hình 49. Kết quả nhận dạng “bình thường”	40

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Ý nghĩa
CNN	Mạng neural tích chập
DenseNet	Mạng kết nối dày đặc
LSTM	Mạng bộ nhớ ngắn hạn dài
GRU	Mạng neural hồi tiếp với nút có cổng
GAN	Mạng sinh đối nghịch
ReLU	Hàm tuyến tính chỉnh lưu
ResNet	Mạng phần dư
RNN	Mạng neural hồi quy

CHƯƠNG 1. ĐẶT VẤN ĐỀ

1.1. Lý do chọn đề tài

Trong những năm gần đây, công nghệ thông tin đã phát triển với tốc độ chóng mặt, đặc biệt là trong lĩnh vực y khoa, khi việc ứng dụng công nghệ thông tin vào quá trình chẩn đoán và điều trị bệnh đã trở nên phổ biến. Ảnh y khoa là một công cụ không thể thiếu trong quá trình chẩn đoán từ X-quang đến siêu âm. Đối với các bác sĩ, phân tích và diễn giải ảnh y khoa đòi hỏi sự chính xác và kinh nghiệm lâm sàng cao. Điều này tạo ra áp lực lớn cho các bác sĩ, đặc biệt là trong bối cảnh số lượng ảnh y khoa ngày càng tăng và cần được xử lý nhanh chóng. Công việc này yêu cầu một phương pháp hiệu quả để tăng cường khả năng chẩn đoán và điều trị, giúp bác sĩ nhanh chóng xác định vấn đề sức khỏe của bệnh nhân.

Với những lý do trên, em đã chọn đề tài "Phát hiện bất thường trong ảnh y khoa" để nghiên cứu nhằm hỗ trợ bác sĩ trong việc phân tích ảnh y khoa, giảm bớt gánh nặng công việc và tăng độ chính xác trong chẩn đoán. Bằng cách sử dụng các mô hình học sâu, chúng có khả năng tự động phát hiện các dấu hiệu bất thường, từ đó cung cấp thông tin hữu ích cho quá trình đánh giá và quyết định lâm sàng của bác sĩ.

Ngoài ra, việc phát triển các mô hình này cũng góp phần nâng cao chất lượng dịch vụ y tế và mở ra hướng nghiên cứu mới trong việc ứng dụng công nghệ thông tin vào y khoa. Em hy vọng rằng, đề tài này sẽ góp phần vào sự phát triển của ngành y tế và công nghệ thông tin. Đây chính là động lực và mục tiêu quan trọng của em trong quá trình thực hiện khoá luận tốt nghiệp này.

1.2. Mục tiêu

Mục tiêu của khoá luận này là đề xuất và phát triển phương pháp hiệu quả để phát hiện bất thường trong ảnh y khoa. Cụ thể, khoá luận sẽ tập trung vào các mục tiêu sau:

- Giới thiệu về lĩnh vực phát hiện bất thường trên ảnh y khoa và các phương pháp hiện đang có, từ đó xác định những hạn chế và thách thức cần được giải quyết.
- Tìm hiểu về các mô hình học sâu, xây dựng các mô hình sao cho chúng có khả năng tự động phát hiện các dấu hiệu bất thường từ dữ liệu ảnh y khoa với độ chính xác cao và thời gian xử lý nhanh chóng.
- Đánh giá hiệu suất của các mô hình thông qua các thử nghiệm trên bộ dữ liệu thực tế, so sánh và đưa ra các cải tiến cần thiết.

1.3. Nội dung

Giới thiệu về học sâu, trình bày cách hoạt động của các mô hình học sâu phổ biến.

Mô tả về bài toán, giới thiệu một số kết quả đã đạt được trong việc giải quyết bài toán và mô tả về các phương pháp hiện đã và đang được sử dụng với những kết quả đã đạt được và những hạn chế của chúng.

Đề xuất mô hình cho quá trình phát hiện bất thường, cùng với việc thu thập và tiền xử lý dữ liệu, xây dựng mô hình, huấn luyện mô hình, và đánh giá hiệu suất của mô hình.

1.4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của khoá luận này sẽ tập trung vào các hình ảnh y khoa bình thường và bất thường, có thể là các bức ảnh chụp từ thiết bị, hoặc có thể là ảnh chụp từ một nhóm bệnh nhân với điều kiện sức khỏe nhất định được sử dụng để phát hiện các bất thường, bệnh lý, hoặc các dấu hiệu sớm của bệnh tật.

Phạm vi của nghiên cứu sẽ bao gồm các phương pháp và mô hình học sâu được áp dụng để phát hiện bất thường trong ảnh y khoa. Mô hình sẽ được thử nghiệm và đánh giá trên tập dữ liệu chứa các hình ảnh y khoa đa dạng và phong phú. Ngoài ra, phạm vi cũng xem xét đến các yếu tố như độ phức tạp của mô hình, thời gian xử lý, việc phân tích và xử lý số liệu độ chính xác, hiệu quả của các mô hình.

1.5. Phương pháp nghiên cứu

- Phương pháp nghiên cứu lý thuyết:

Đọc và tổng hợp tài liệu liên quan: Tìm kiếm và nghiên cứu các bài báo khoa học, sách, và tài liệu chuyên ngành liên quan đến phát hiện bất thường trong ảnh y khoa và các mô hình học sâu.

Phân tích các phương pháp hiện có: Đánh giá các phương pháp và kỹ thuật hiện có trong lĩnh vực học sâu và xử lý ảnh y khoa để xác định các ưu điểm và hạn chế của chúng.

Xây dựng cơ sở lý thuyết: Phát triển nền tảng lý thuyết dựa trên kiến thức thu thập được, từ đó định hướng cho phương pháp nghiên cứu thực nghiệm.

- Phương pháp nghiên cứu thực nghiệm:

Thu thập các bộ dữ liệu ảnh y khoa từ các nguồn đáng tin cậy.

Tiền xử lý dữ liệu để chuẩn hóa và làm sạch dữ liệu.

Xây dựng các mô hình học sâu.

Huấn luyện mô hình trên các bộ dữ liệu đã được tiền xử lý.

Đánh giá hiệu suất của mô hình bằng các độ đo.

Phân tích kết quả thực nghiệm để rút ra các kết luận về hiệu suất và tính khả thi của các mô hình, và đề xuất các cải tiến hoặc hướng nghiên cứu tiếp theo dựa trên kết quả đó.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Sơ lược về học sâu

2.1.1. Định nghĩa

Học sâu là một nhánh của học máy, sử dụng các mô hình mạng neural sâu để xử lý dữ liệu phức tạp và thực hiện các nhiệm vụ như phân loại, dự đoán và phát hiện.

Học sâu tập trung vào việc xây dựng và huấn luyện các mạng neural với nhiều lớp ẩn. Khác với các phương pháp truyền thống, học sâu cho phép mô hình hóa các bài toán phức tạp và tìm ra mối liên hệ không tuyến tính giữa các đặc trưng đó bằng cách tự động học các đặc trưng của dữ liệu đầu vào [1].

Học sâu sử dụng các thuật toán được thiết kế để dạy máy tính xử lý dữ liệu tương tự như cách bộ não con người hoạt động. Mô hình học sâu có khả năng nhận diện và phân tích các đối tượng phức tạp trong hình ảnh, văn bản, âm thanh,... từ đó trích xuất ra các thông tin hữu ích và đưa ra dự đoán chính xác [2].

2.1.2. Ứng dụng


Học sâu được ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau như: phân loại, nhận dạng, dự đoán và dự báo, xử lý ngôn ngữ tự nhiên,... [3]. Sự phát triển của các thuật toán học sâu đã thúc đẩy tiến bộ trong việc xử lý dữ liệu không cấu trúc, mở ra khả năng giải quyết các vấn đề phức tạp mà trước đây được coi là không thể. Với khả năng tự học từ dữ liệu lớn và phức tạp, học sâu đã chứng minh tiềm năng to lớn trong việc mô phỏng các quá trình nhận thức của con người và thậm chí còn vượt qua hiệu suất của con người trong một số lĩnh vực cụ thể.

Tuy nhiên, học sâu cũng đối mặt với nhiều thách thức lớn mà một trong những số đó là yêu cầu về dữ liệu lớn và sự phụ thuộc vào các tài nguyên tính toán mạnh mẽ. Mạng neural sâu cần một lượng lớn dữ liệu huấn luyện để có thể học được các đặc trưng phức tạp và tránh hiện tượng quá khớp khi mô hình chỉ hoạt động tốt trên dữ liệu huấn luyện nhưng không tổng quát hóa được trên dữ liệu mới. Ngoài ra, việc huấn luyện các mô hình học sâu thường đòi hỏi phần cứng chuyên biệt, như GPU hoặc TPU, để xử lý các phép tính song song cần thiết cho việc cập nhật trọng số mạng nhanh chóng [4].

2.1.3. Cấu tạo chung của một mô hình học sâu

Mô hình học sâu là một loại mô hình máy học có khả năng tự động học và trích xuất đặc trưng từ dữ liệu đầu vào thông qua việc sử dụng nhiều lớp xử lý tương tác với nhau, mỗi lớp thực hiện một phần nhất định của quá trình học. Thông thường các lớp này bao

gồm lớp đầu vào, lớp ẩn, và lớp đầu ra [5]. Lớp đầu vào là nơi mà dữ liệu được cung cấp cho mô hình, qua đó mô hình có thể học được các đặc trưng từ dữ liệu. Lớp ẩn, thường có nhiều lớp nhỏ hơn, là nơi xử lý thông tin, thông qua các hàm kích hoạt không tuyến tính, giúp mô hình có khả năng học được các đặc trưng phức tạp và mối quan hệ giữa chúng. Lớp đầu ra là nơi mô hình đưa ra dự đoán hoặc kết quả dựa trên những gì đã học được.



Hình 1. Cấu tạo chung một mô hình học sâu [5]

Mỗi lớp trong mô hình học sâu chứa một tập hợp các đơn vị xử lý gọi là neural, mỗi neural có khả năng tính toán và truyền thông tin từ lớp này sang lớp khác thông qua các kết nối có trọng số.

Các mô hình này thường được huấn luyện thông qua một quá trình có giám sát, nửa giám sát hoặc không giám sát, tùy thuộc vào loại dữ liệu và nhiệm vụ cụ thể. Trong quá trình học, mô hình sẽ điều chỉnh các trọng số của mình để giảm thiểu sai số giữa đầu ra dự đoán và đầu ra thực tế [5].

Một trong những đặc điểm quan trọng của học sâu là khả năng tự học biểu diễn đặc trưng, loại bỏ nhu cầu phải thiết kế thủ công các đặc trưng vốn thường đòi hỏi kiến thức chuyên môn sâu và thời gian dài. Thay vào đó, mô hình học sâu có thể tự động phát hiện các đặc trưng quan trọng từ dữ liệu thông qua khả năng tự học và điều chỉnh các trọng số của các kết nối, làm mô hình trở nên mạnh mẽ và linh hoạt [5].

2.1.4. Các bước hoạt động của một mô hình học sâu

Mô hình học sâu hoạt động theo các bước cơ bản như sau [6, 7]:

- Nhận dữ liệu đầu vào: Mô hình nhận dữ liệu đầu vào từ tập huấn luyện, bao gồm các điểm dữ liệu và nhãn tương ứng (nếu có).
- Chuyển tiếp: Dữ liệu đầu vào được chuyển tiếp qua các lớp của mô hình từ lớp đầu vào đến lớp đầu ra. Trong quá trình này, các phép tính toán tương ứng với các trọng số của mô hình được thực hiện để tạo ra đầu ra dự đoán.
- Tính toán lỗi: Đầu ra dự đoán của mô hình được so sánh với nhãn thực tế của dữ liệu huấn luyện để tính toán lỗi. Lỗi thường được đo lường bằng một hàm mất mát phù hợp với loại bài toán, ví dụ như Cross-Entropy Loss cho bài toán phân loại.
- Lan truyền ngược: Sau khi tính toán lỗi, mô hình sử dụng thuật toán lan truyền ngược để cập nhật các trọng số của mạng neural. Quá trình này lan truyền lỗi từ lớp đầu ra trở về lớp đầu vào, điều chỉnh các trọng số sao cho lỗi giảm dần qua mỗi lần cập nhật, giúp mạng tự điều chỉnh thông qua dữ liệu và cải thiện dự đoán của mình theo thời gian.
- Cập nhật trọng số: Các trọng số của mô hình được cập nhật dựa trên đạo hàm của hàm mất mát theo các trọng số và tốc độ học giúp điều chỉnh các tham số sao cho đầu ra dự đoán gần với nhãn thực tế nhất.
- Lặp lại quá trình: Các quá trình chuyển tiếp, tính toán lỗi, lan truyền ngược và cập nhật trọng số được lặp lại cho đến khi mô hình đạt được hiệu suất mong muốn hoặc khi điều kiện dừng được đáp ứng.

2.2. Các mô hình học sâu

Có nhiều mô hình học sâu phổ biến được sử dụng như: CNN, RNN, autoencoder,.... Mỗi mô hình có những đặc điểm riêng biệt và ứng dụng phù hợp cho từng loại dữ liệu và nhiệm vụ cụ thể.

Dưới đây trong từng mục, chúng ta sẽ giới thiệu chi tiết về các mô hình học sâu này.

2.2.1. Mạng CNN

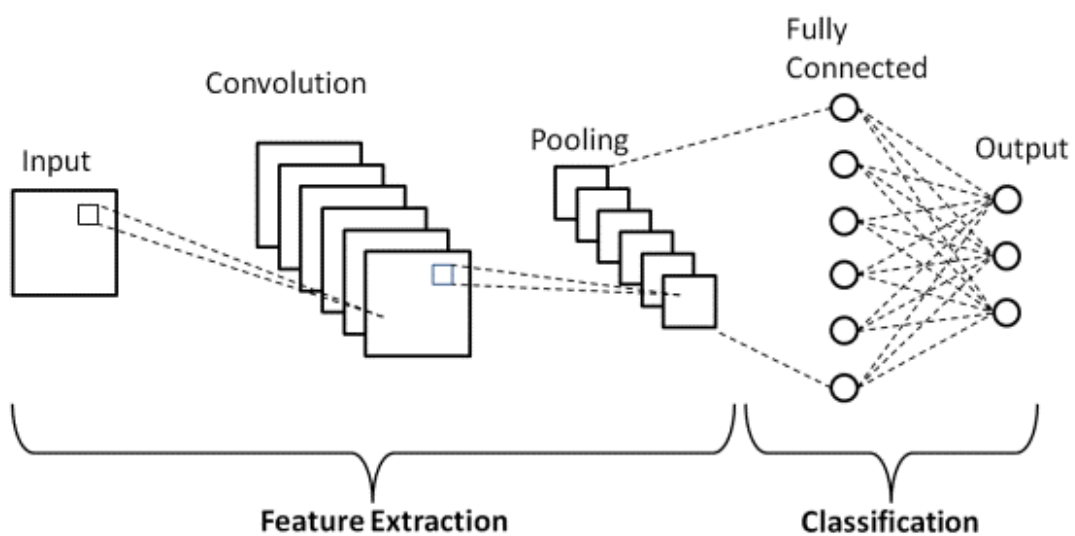
Mạng CNN là một trong những mô hình học sâu phổ biến nhất và mạnh mẽ nhất trong lĩnh vực thị giác máy tính. Nó được sử dụng rộng rãi trong các tác vụ liên quan đến hình ảnh và video. CNN có thể học được các đặc trưng của hình ảnh từ dữ liệu đầu vào, giúp cho việc nhận dạng và phân loại hình ảnh trở nên dễ dàng và chính xác.

Cấu trúc cơ bản của một mạng CNN có thể bao gồm các lớp sau [8]:

- Lớp tích chập (convolution): Lớp này sử dụng các bộ lọc (filters hoặc kernel) để trích xuất các đặc trưng từ dữ liệu đầu vào. Các bộ lọc này được áp dụng trên toàn

bộ ảnh bằng cách trượt qua từng phần của ảnh để mã hóa thông tin có ích và loại bỏ thông tin không cần thiết. Kết quả của quá trình này là một bản đồ đặc trưng (feature map) có thể chứa các đặc trưng cục bộ của ảnh như cạnh, góc, và các đặc điểm nổi bật khác.

- Lớp gộp (pooling): Lớp này thường được sử dụng sau các lớp tích chập để giảm kích thước không gian của đặc trưng và giảm độ phức tạp của mô hình bằng cách tổng hợp thông tin qua phép lấy mẫu. Phép lấy mẫu có thể là gộp theo giá trị lớn nhất (max pooling), trong đó giá trị lớn nhất trong mỗi vùng được chọn làm đại diện, hoặc là gộp theo giá trị trung bình, trong đó giá trị trung bình của mỗi vùng được tính toán.
- Hàm kích hoạt (activation function): Hàm kích hoạt được áp dụng sau mỗi lớp tích chập hoặc lớp gộp để tạo ra đầu ra phi tuyến tính của mô hình, cho phép mô hình học được các biểu diễn phức tạp hơn.. Hàm kích hoạt phổ biến nhất là ReLU, nhưng cũng có thể sử dụng các hàm khác như Tanh hoặc Sigmoid.
- Lớp kết nối đầy đủ (fully connected): Sau khi đã trích xuất các đặc trưng từ dữ liệu đầu vào, các đặc trưng này sẽ được đưa vào các lớp kết nối đầy đủ để phân loại. Các lớp này thường kết hợp với các lớp dropout để tránh quá khớp (overfitting) và cải thiện khả năng tổng quát hóa của mô hình.
- Lớp đầu ra (output): Lớp cuối cùng của mạng CNN, thường sử dụng hàm kích hoạt softmax để tính toán xác suất của các lớp đầu ra và dự đoán nhãn của ảnh đầu vào.




Hình 2. Cấu tạo chung của mạng CNN [8]

2.2.2. Mạng RNN

Mạng RNN là một loại mạng neural có khả năng xử lý dữ liệu chuỗi và có bộ nhớ ngắn hạn. RNN được thiết kế để nhận diện và tận dụng thông tin của các sự kiện trước đó trong chuỗi dữ liệu. RNN hoạt động hiệu quả với các bài toán liên quan đến dữ liệu tuần tự như ngôn ngữ tự nhiên hoặc chuỗi thời gian.

Cấu trúc cơ bản của một mạng RNN bao gồm [9, 10]:

- Lớp đơn vị (cell): Đây là lớp cơ bản của mạng RNN, mỗi đơn vị trong lớp này có trạng thái ẩn (hidden state) được cập nhật sau mỗi bước thời gian dựa trên đầu vào hiện tại và trạng thái ẩn của bước thời gian trước đó. Trạng thái ẩn này chứa thông tin về lịch sử của dữ liệu chuỗi.
- Lớp đầu ra: Lớp này thường được đặt sau mỗi đơn vị RNN để tạo ra đầu ra dự đoán tại mỗi bước thời gian. Trong cấu trúc của RNN, các nút được kết nối vòng lại với chính chúng, cho phép thông tin được truyền từ bước thời gian này sang bước thời gian khác.



Hình 3. Cấu tạo chung của một mạng RNN [9]

RNN hoạt động dựa trên nguyên lý truyền thông tin từ bước thời gian này sang bước thời gian khác, cho phép lưu giữ trạng thái tạm thời và "nhớ" thông tin từ quá khứ. Quá trình huấn luyện của RNN cũng sử dụng phương pháp lan truyền ngược qua thời gian để cập nhật trọng số của mạng.


RNN được sử dụng trong nhiều ứng dụng khác nhau, từ dự đoán chuỗi thời gian trong tài chính, dự báo thời tiết, đến nhận dạng giọng nói, dịch máy, phân tích video và xử lý ngôn ngữ tự nhiên. Chúng cũng được áp dụng trong việc tạo ra văn bản tự động, nơi mà mạng có thể học cách tạo ra văn bản có cấu trúc và ngữ nghĩa tương tự như văn bản huấn luyện ban đầu.

Mạng RNN có khả năng mô hình hóa dữ liệu dạng chuỗi và mối quan hệ giữa các thành phần của chuỗi, giúp nắm bắt được thông tin liên quan đến thời gian trong dữ liệu.

Tuy nhiên, một trong những hạn chế của RNN là khả năng xử lý dữ liệu dài với hiện tượng mất mát thông tin qua thời gian, hay còn gọi là vấn đề "mất mát đạo hàm" (vanishing gradient) khiến cho việc học các phụ thuộc dài hạn trở nên khó khăn. Để giải quyết vấn đề này, các biến thể của RNN đã được phát triển và sử dụng [11], trong đó phổ biến nhất là:

- LSTM: LSTM có khả năng lưu giữ thông tin qua nhiều bước thời gian nhờ vào các cổng kiểm soát giúp điều chỉnh dòng thông tin.
- GRU: GRU là một phiên bản đơn giản hơn của LSTM, cũng sử dụng các cổng kiểm soát để điều chỉnh thông tin, nhưng có cấu trúc gọn gàng hơn.

Cả hai đều được thiết kế để có thể lưu giữ thông tin qua nhiều bước thời gian mà không gặp phải vấn đề mất mát đạo hàm.



Hình 4. Cấu tạo của ba mạng RNN, LSTM và GRU [11]

Mạng RNN và các biến thể của nó đóng vai trò quan trọng trong việc mô hình hóa dữ liệu tuần tự và giải quyết các bài toán liên quan đến thời gian, góp phần quan trọng trong nhiều ứng dụng công nghệ hiện đại.


2.2.3. Mạng Autoencoder

Mạng Autoencoder là một loại mạng neural được thiết kế để tự động học và trích xuất các đặc trưng quan trọng từ dữ liệu đầu vào bằng cách nén (encoding) và sau đó phục hồi (decoding) dữ liệu từ biểu diễn nén đó [12].

Cấu trúc của một mạng Autoencoder có ba phần chính [13]:

- Phần nén (encoder): Nhận đầu vào và biến đổi nó thành một biểu diễn nén có kích thước nhỏ hơn, thường được gọi là latent. Trong quá trình huấn luyện, phần này học cách trích xuất các đặc trưng quan trọng từ dữ liệu.
- Phần ẩn (latent layer): Đây là lớp ẩn giữa, nơi chứa biểu diễn nén của dữ liệu. Biểu diễn này mang thông tin quan trọng giúp mạng học được các đặc trưng từ dữ liệu.
- Phần giải nén (decoder): Nhận biểu diễn nén từ phần ẩn để tái tạo lại đầu vào ban đầu.

đầu từ biểu diễn nén đó. Trong quá trình huấn luyện, phần giải nén học cách phục hồi lại dữ liệu từ biểu diễn nén và cải thiện chất lượng của dữ liệu tái tạo. Mục tiêu của quá trình này là giảm sự khác biệt giữa dữ liệu đầu vào và dữ liệu được tái tạo.



Hình 5. Cấu tạo của mạng Autoencoder [13]

Để huấn luyện một mạng Autoencoder, chúng ta cũng sử dụng thuật toán lan truyền ngược và hàm mất mát, tương tự như khi huấn luyện các mạng neural khác. Tuy nhiên, điểm khác biệt chính là thay vì huấn luyện mạng để dự đoán nhãn hoặc giá trị đầu ra, Autoencoder được huấn luyện để tái tạo lại chính dữ liệu đầu vào của nó; đòi hỏi mạng phải học cách nắm bắt và biểu diễn thông tin một cách hiệu quả trong code mà không cần đến sự giám sát từ nhãn dữ liệu. Khi mạng Autoencoder được huấn luyện đủ tốt, nó có thể tái tạo lại dữ liệu đầu vào một cách chính xác.

Autoencoder có nhiều ứng dụng trong học máy như phát hiện bất thường, giảm chiều dữ liệu, và khử nhiễu từ ảnh. Ngoài ra, Autoencoder còn có thể được sử dụng để tạo ra dữ liệu mới, có khả năng mô phỏng dữ liệu thực tế, thông qua quá trình tái tạo dữ liệu từ code.

2.2.4. Mạng GAN


Mạng GAN là một dạng kiến trúc mạng neural đặc biệt được đề xuất bởi Ian Goodfellow và các đồng nghiệp vào năm 2014. Mạng GAN được thiết kế để tạo ra dữ liệu mới từ dữ liệu huấn luyện, có ứng dụng trong nhiều lĩnh vực như tạo ảnh, tạo âm thanh,....

Mạng GAN bao gồm hai thành phần chính [14]:

- Phần sinh (generator): có nhiệm vụ tạo ra dữ liệu giả mạo từ dữ liệu ban đầu. Nó

thường được cấu tạo từ các lớp neural tích chập chuyển vị (transposed convolution hay còn gọi là deconvolutional) để chuyển đổi vector latent space thành dữ liệu giả mạo có cấu trúc. Phần sinh cố gắng tạo ra dữ liệu sao cho giống với dữ liệu thật nhất có thể để đánh lừa phần nhận dạng (discriminator).

- Phần nhận dạng: Mạng này được huấn luyện để phân biệt giữa dữ liệu thật và dữ liệu giả mạo. Nó thường được cấu thành từ các lớp neural tích chập để trích xuất đặc trưng và các lớp kết nối đầy đủ để phân loại.



Hình 6. Cấu tạo của mạng GAN [14]

Quá trình huấn luyện của mạng GAN diễn ra như một trò chơi giữa phần sinh và phần nhận dạng: phần sinh cố gắng tạo ra dữ liệu giả mạo sao cho phần nhận dạng không thể phân biệt được, trong khi phần nhận dạng cố gắng tìm ra cách phân biệt giữa dữ liệu thật và giả mạo. Quá trình này liên tục lặp đi lặp lại, giúp cả hai phần cải thiện khả năng của chúng.


2.2.5. Mạng ResNet

Mạng ResNet là một kiến trúc mạng neural tích chập sâu được giới thiệu bởi Kaiming He và các cộng sự tại Microsoft Research vào năm 2015. ResNet sử dụng các đơn vị khối phần dư (residual blocks), cho phép xây dựng mạng được đến hàng trăm hoặc thậm chí hàng nghìn tầng.

Cấu trúc cơ bản của ResNet bao gồm các khối phần dư. Mỗi khối phần dư bao gồm một loạt các lớp được nối với nhau theo cấu trúc "ánh xạ đồng nhất" (identity mapping). Trong từng khối thường có một lớp tích chập, một lớp chuẩn hóa theo lô, và một hàm kích

hoạt ReLU. ResNet sử dụng các kết nối tắt hay còn gọi là kết nối phần dư, trong đó đầu vào của một lớp được cộng trực tiếp vào đầu ra của lớp sau một số lớp trung gian. Phương pháp này giúp huấn luyện mạng trên hàng ngàn lớp mà không ảnh hưởng đến hiệu suất. Lợi ích của việc thêm loại kết nối tắt này là nếu bất kỳ lớp nào làm ảnh hưởng đến hiệu suất của mô hình thì nó sẽ được điều chỉnh để bỏ qua. Vì vậy, kết quả thu được là việc huấn luyện một mạng neural rất sâu mà không gặp phải các vấn đề do biến mất gradient giúp mạng học được các biểu diễn đặc trưng hơn [15].

ResNet có nhiều biến thể với số lượng lớp khác nhau như ResNet18, ResNet34, ResNet50, ResNet101, và ResNet152. Số lượng lớp càng nhiều thì mô hình càng sâu và có khả năng học được nhiều đặc trưng phức tạp hơn, nhưng cũng đòi hỏi nhiều tài nguyên tính toán hơn.




Hình 7. Cấu tạo của một biến thể ResNet – ResNet18 [15]

Nhờ vào khả năng học được các đặc trưng sâu, ResNet có thể giúp cải thiện hiệu suất phát hiện bất thường và giảm thiểu việc mất mát thông tin trong quá trình lan truyền ngược.

2.2.6. Mạng DenseNet

Mạng DenseNet là một kiến trúc mạng neural sâu được giới thiệu bởi Gao Huang và các cộng sự vào năm 2017 [16]. DenseNet đã cách mạng hóa lĩnh vực thị giác máy tính bằng cách đề xuất một mô hình kết nối mới trong CNN, giải quyết các vấn đề như tái sử dụng đặc trưng và vấn đề mất mát đạo hàm. Khác với các kiến trúc CNN truyền thống khi mà mỗi lớp chỉ được kết nối với các lớp tiếp theo, DenseNet thiết lập các kết nối trực tiếp giữa tất cả các lớp trong một khối bằng cách sử dụng kỹ thuật gọi là “kết nối dày đặc” (dense connection). Kết nối dày đặc là một kỹ thuật trong đó đầu ra của mỗi lớp được kết nối đến tất cả các lớp sau đó. Điều này cho phép gradient được truyền thẳng qua mạng, giúp cải thiện hiệu suất huấn luyện.

Mạng DenseNet được xây dựng từ các khối dày đặc (dense block). Một khối dày đặc bao gồm một loạt các lớp tích chập được kết nối với nhau, mỗi lớp sau đó được theo sau bởi một hàm kích hoạt ReLU. Các đầu ra của các lớp tích chập được nối lại với nhau bằng cách sử dụng phép nối (concatenate), tạo thành một đầu ra dày đặc (dense output) giúp cải thiện hiệu suất huấn luyện bằng cách tận dụng lại thông tin từ tất cả các lớp trước đó [17].



Hình 8. Cấu tạo của mạng DenseNet [17]

Nhờ vào khả năng của nó trong việc tận dụng lại thông tin từ tất cả các lớp, mạng DenseNet có thể học được biểu diễn phức tạp của dữ liệu hình ảnh và tăng cường hiệu suất phát hiện. Ngoài ra, DenseNet cũng hiệu quả về mặt số lượng tham số bằng cách loại bỏ nhu cầu phải học lại các đặc trưng dư thừa, dẫn đến số lượng tham số ít hơn so với các mạng truyền thống.

2.3. Quy trình huấn luyện và đánh giá một mô hình học sâu

Các bước thực hiện chính như sau:

- Thu thập dữ liệu: Nguồn hình ảnh y khoa có thể được thu thập từ các nguồn khác nhau như máy chụp cắt lớp hay hình ảnh X-quang.
- Tiền xử lý dữ liệu: có thể bao gồm chuẩn hóa, loại bỏ nhiễu, tách tập dữ liệu hoặc tăng cường dữ liệu.
- Xây dựng mô hình học sâu bằng cách xem xét và lựa chọn các mô hình học sâu như CNN, ResNet, DenseNet,..., sau đó tiến hành cài đặt mô hình và thiết lập các tham

số của mô hình như số lượng lớp, kích thước lớp, hàm kích hoạt.

- Huấn luyện mô hình: Sử dụng dữ liệu đã chuẩn bị để huấn luyện mô hình. Quá trình huấn luyện bao gồm việc tối ưu hóa các tham số của mô hình thông qua các thuật toán học sâu để tối ưu hóa hiệu suất.
- Đánh giá mô hình: Sau khi huấn luyện, mô hình sẽ được đánh giá trên tập dữ liệu kiểm tra. Các chỉ số như độ chính xác, F1-score hoặc độ nhạy sẽ được sử dụng để đo lường hiệu suất của mô hình. Nếu cần thiết, dựa trên kết quả đánh giá, điều chỉnh các siêu tham số hoặc cấu trúc của mô hình để cải thiện hiệu suất.

CHƯƠNG 3. HIỆN THỰC HÓA NGHIÊN CỨU

3.1. Mô tả bài toán

Phát hiện bất thường trong ảnh là một phần quan trọng trong lĩnh vực y học hình ảnh, nhằm nhận diện các khu vực hoặc đối tượng trong hình ảnh y khoa mà không tuân theo mẫu chuẩn hoặc có sự biến đổi bất thường so với trạng thái bình thường. Bài toán này đòi hỏi độ chính xác cao do mức độ nghiêm trọng của việc chẩn đoán sai lệch. Do đó, việc thu thập và xử lý dữ liệu cần phải được thực hiện một cách cẩn thận, đảm bảo tính toàn vẹn và độ tin cậy của dữ liệu.

Đầu vào của bài toán là ảnh y khoa, các ảnh này có kích thước lớn và độ phức tạp cao, với các đối tượng và biến đổi bất thường xuất hiện ở nhiều hình dạng và kích thước khác nhau. Sau đó các ảnh sẽ được đưa vào các mô hình để nhận dạng. Đầu ra của bài toán cho biết hình ảnh đầu vào là bình thường hay bất thường.

Trong phạm vi của khoá luận này, bài toán sẽ đề cập về viêm phổi. Viêm phổi là một bệnh nhiễm trùng phổi gây ra bởi vi khuẩn, virus hoặc nấm; bệnh làm viêm các túi khí trong phổi, gây ra triệu chứng như ho, sốt, khó thở và đau ngực. Viêm phổi có thể ảnh hưởng nghiêm trọng, đặc biệt ở người già, trẻ em và những người có hệ miễn dịch yếu. Phát hiện sớm viêm phổi là rất quan trọng để điều trị kịp thời và giảm thiểu biến chứng. Các phương pháp chẩn đoán truyền thống như chụp X-quang và xét nghiệm máu có thể mất thời gian và không phải lúc nào cũng chính xác. Do đó, việc áp dụng các mô hình học sâu để phát hiện viêm phổi từ ảnh y khoa đang trở thành một hướng nghiên cứu tiềm năng. Các mô hình học sâu có thể tự động phát hiện các dấu hiệu của viêm phổi từ ảnh X-quang với độ chính xác cao. Điều này không chỉ giúp cải thiện tốc độ chẩn đoán mà còn hỗ trợ các bác sĩ trong việc đưa ra quyết định điều trị.

3.2. Những kết quả đã đạt được trước đó

Các nghiên cứu trước đây đã tiếp cận vấn đề này thông qua nhiều phương pháp khác như phân tích thành phần chính và máy vector hỗ trợ [18]. Một số nghiên cứu đã tập trung vào việc mô hình hóa nền để phát hiện sự bất thường dựa trên sự khác biệt so với nền thông thường, trong khi những nghiên cứu khác lại hướng đến việc phát hiện bất thường thông qua việc phân tích ảnh dư, nơi mà nhiễu và bất thường là chủ đạo [19]. Các phương pháp này đã được chứng minh là có hiệu quả trong việc phát hiện các loại bất thường khác nhau, từ những thay đổi nhỏ trong kết cấu mô đến những khối u lớn.

Tuy nhiên, việc phát hiện bất thường trong ảnh y khoa vẫn còn nhiều thách thức,

bao gồm việc xác định những gì là "bình thường" và "bất thường", sự đa dạng của các loại bất thường, và khả năng của mô hình trong việc tổng quát hóa từ dữ liệu huấn luyện đến dữ liệu thực tế.

Nghiên cứu này tập trung vào việc xem xét và phát triển các mô hình học sâu để giải quyết những hạn chế của các phương pháp hiện tại, và có khả năng thích ứng tốt hơn với sự đa dạng của dữ liệu y khoa và cải thiện độ chính xác trong việc phát hiện bất thường.

3.3. Đề xuất cách giải quyết bài toán

Các mô hình học sâu đã được chứng minh là hiệu quả trong việc xử lý dữ liệu không cân xứng, giúp giảm thiểu sự thiên vị về phía nhóm dữ liệu lớn hơn, điều này rất quan trọng trong xử lý ảnh y khoa vì đôi khi số lượng ảnh cho trường hợp bình thường thường nhiều hơn so với trường hợp bất thường và cũng có khi ngược lại.

Vì vậy, trong khoá luận này, em sử dụng các mô hình học sâu bao gồm mạng CNN, mạng ResNet, và mạng DenseNet. Các mô hình này đặc biệt phù hợp với việc trích xuất đặc trưng từ ảnh và học các đặc trưng phức tạp và quan trọng để phân biệt giữa các vùng bình thường và bất thường trong ảnh y khoa.

Ngoài ra, các mô hình này còn sử dụng các lớp phi tuyến tính với các hàm kích hoạt như ReLU và Sigmoid để tăng khả năng học của mạng. Phương pháp tối ưu hóa Adam được chọn để điều chỉnh trọng số của mạng, giúp mô hình hội tụ nhanh và hiệu quả hơn.

Chương 4 sẽ trình bày chi tiết về kiến trúc của từng mô hình được đề xuất.

3.4. Giới thiệu tập dữ liệu

Tập dữ liệu được sử dụng trong khoá luận là tập dữ liệu hình ảnh X-quang phổi (Chest X-Ray Images (Pneumonia)).

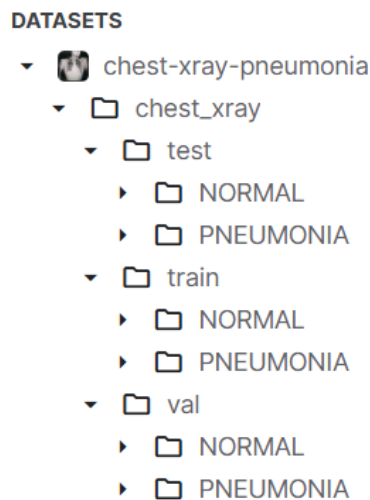
Dữ liệu được cung cấp bởi bài viết “Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images for Classification” của các tác giả Daniel Kermany, Kang Zhang và Michael Goldbaum trên kho lưu trữ Mendeley Data [20] và được được sưu tập và tổng hợp bởi tác giả Paul Mooney trên nền tảng Kaggle. [21]

Tập dữ liệu bao gồm tổng cộng 5,863 hình ảnh X-Ray có định dạng JPEG được tổ chức thành 3 thư mục train, val, test tương ứng là huấn luyện, đánh giá và kiểm tra. Mỗi thư mục con chứa các thư mục con nhỏ hơn cho từng danh mục hình ảnh tương ứng với hai nhãn bình thường và viêm phổi.

Để phân tích hình ảnh X-quang ngực, tất cả các phim X-quang ngực ban đầu được sàng lọc để kiểm soát chất lượng bằng cách loại bỏ tất cả các bản quét chất lượng thấp hoặc

không thể đọc được. Các chẩn đoán cho hình ảnh sau đó được hai bác sĩ chuyên môn phân loại trước khi được cho phép huấn luyện hệ thống. Để giải quyết bất kỳ lỗi đánh giá nào, bộ đánh giá cũng đã được kiểm tra bởi một bác sĩ chuyên môn thứ ba. [21]

Tập dữ liệu này được sử dụng để hỗ trợ việc phân loại bệnh viêm phổi thông qua hình ảnh X-quang, đồng thời là nguồn dữ liệu quan trọng cho các nghiên cứu và phát triển mô hình học máy trong lĩnh vực y tế.



Hình 9. Cây thư mục của tập dữ liệu

3.5. Môi trường cài đặt

Để triển khai và huấn luyện mô hình, khoá luận sử dụng Kaggle, một nền tảng trực tuyến nổi tiếng trong cộng đồng khoa học dữ liệu và học máy. Được thành lập vào năm 2010 và hiện là một phần của Google, Kaggle cung cấp một môi trường làm việc toàn diện cho các chuyên gia và những người đam mê trong lĩnh vực này để thực hành, cạnh tranh và học hỏi từ nhau.

Kaggle cho phép người dùng viết và chạy mã trực tiếp trong trình duyệt mà không cần thiết lập môi trường cục bộ. Kaggle cung cấp một môi trường tính toán đám mây, giúp người dùng thực hiện các dự án khoa học dữ liệu và xây dựng mô hình học máy mà không cần cấu hình máy tính quá mạnh. Kaggle hỗ trợ Python và R, hai ngôn ngữ phổ biến nhất trong khoa học dữ liệu. Kaggle cung cấp sẵn các tài nguyên tính toán cần thiết, bao gồm GPU và TPU, giúp tăng tốc quá trình xử lý và huấn luyện mô hình.

Kaggle còn cho phép khả năng kết nối trực tiếp với các bộ dữ liệu trên Kaggle, giúp quá trình tải và xử lý dữ liệu trở nên đơn giản và nhanh chóng.

CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU

4.1. Chuẩn bị thư viện và dữ liệu

Khoá luận sử dụng các thư viện của Python để xây dựng và thiết lập các mô hình học sâu như thể hiện trong hình sau:

```
import tensorflow as tf
import keras
from keras import datasets, layers, models
from keras.layers import Input, Dense, Conv2D, MaxPooling2D, UpSampling2D, concatenate
from keras.models import Model
import numpy as np
```

```
from keras.applications.resnet50 import ResNet50
from keras.layers import Dense, GlobalAveragePooling2D
from keras.optimizers import Adam
```

```
import matplotlib.pyplot as plt
```

Hình 10. Các thư viện cho việc xây dựng các mô hình

TensorFlow và Keras là hai thư viện phổ biến trong lĩnh vực học sâu. TensorFlow cung cấp một nền tảng mạnh mẽ cho việc xây dựng và huấn luyện các mô hình học sâu. Keras, một giao diện Python cho TensorFlow, giúp đơn giản hóa quá trình xây dựng mô hình bằng cách cung cấp các lớp và hàm tiện ích.

Trong thư viện Keras, Layers chứa các lớp cơ bản được sử dụng để xây dựng mô hình học sâu, bao gồm các lớp như Dense (lớp kết nối đầy đủ), Conv2D (lớp tích chập 2 chiều), MaxPooling2D (lớp gộp theo giá trị lớn nhất 2 chiều), và nhiều lớp khác. Các lớp này giúp xây dựng kiến trúc của mô hình học sâu.

Numpy và Matplotlib là hai thư viện quan trọng trong Python. Numpy hỗ trợ các phép toán khoa học và đại số tuyến tính, trong khi Matplotlib hỗ trợ việc vẽ đồ thị và trực quan hóa dữ liệu.

Ngoài ra, do số lượng hình ảnh trong mỗi thư mục chưa được chuẩn, nên chúng ta cần thêm các thư viện sau để sắp xếp lại tập dữ liệu:

```
import shutil
import random
```

Hình 11. Các thư viện dùng cho việc sắp xếp dữ liệu

Thư viện `shutil` cung cấp một số hàm tiện ích cao cấp để thao tác với các tệp và thư mục, như sao chép, di chuyển, hoặc xóa các tệp và thư mục. Nó cũng hỗ trợ việc sao chép quyền truy cập và thời gian của các tệp, cũng như toàn bộ cây thư mục.

Thư viện `random` được sử dụng để tạo ra các số ngẫu nhiên. Nó cung cấp các hàm như `random()`, `randint()`, `uniform()`, và `choice()` để tạo ra các số ngẫu nhiên theo các phân phối khác nhau.

Tiếp theo chúng ta khai báo một số biến dựa trên cấu trúc của tập dữ liệu:

```
dataset_path = '/kaggle/input/chest-xray-pneumonia/chest_xray'
subfolders = ['train', 'val', 'test']
labels = ['NORMAL', 'PNEUMONIA']
total_images = 0
```

Hình 12. Các biến dựa trên cấu trúc của tập dữ liệu

Kiểm tra số lượng hình ảnh trong từng thư mục:

```
def count_images_in_folder(folder_path):
    return len([f for f in os.listdir(folder_path) if os.path.isfile(os.path.join(folder_path, f))])
```

```
for subfolder in subfolders:
    for label in labels:
        folder_path = os.path.join(dataset_path, subfolder, label)
        num_images = count_images_in_folder(folder_path)
        total_images += num_images
        print(f'Thư mục {folder_path} có {num_images} hình ảnh')

print(f'Tổng số hình ảnh trong tập dữ liệu: {total_images}')
```

```
Thư mục /kaggle/input/chest-xray-pneumonia/chest_xray/train/NORMAL có 1341 hình ảnh
Thư mục /kaggle/input/chest-xray-pneumonia/chest_xray/train/PNEUMONIA có 3875 hình ảnh
Thư mục /kaggle/input/chest-xray-pneumonia/chest_xray/val/NORMAL có 8 hình ảnh
Thư mục /kaggle/input/chest-xray-pneumonia/chest_xray/val/PNEUMONIA có 8 hình ảnh
Thư mục /kaggle/input/chest-xray-pneumonia/chest_xray/test/NORMAL có 234 hình ảnh
Thư mục /kaggle/input/chest-xray-pneumonia/chest_xray/test/PNEUMONIA có 390 hình ảnh
Tổng số hình ảnh trong tập dữ liệu: 5856
```

Hình 13. Số lượng hình ảnh trong từng thư mục

Như chúng ta có thể thấy, có sự không tương xứng giữa số lượng hình ảnh của các thư mục với nhau. Do đó trong trường hợp này, chúng ta sẽ sắp xếp và chia lại số lượng hình ảnh giữa các tập dữ liệu theo tỷ lệ là $\text{train:val:test} = 70\%:10\%:20\%$.

Để làm điều đó, chúng ta sẽ thực hiện tạo một thư mục mới chứa tập dữ liệu theo tỷ lệ nêu trên. Mã nguồn sau đây thực hiện công việc đó:

```

for subfolder in subfolders:
    for label in labels:
        folder_path = os.path.join(dataset_path, subfolder, label)
        images = [f for f in os.listdir(folder_path) if os.path.isfile(os.path.join(folder_path,
f))]

        random.seed(42)
        random.shuffle(images)
        num_train = int(0.7 * len(images))
        num_val = int(0.1 * len(images))
        num_test = len(images) - num_train - num_val

        train_images = images[:num_train]
        val_images = images[num_train:num_train + num_val]
        test_images = images[num_train + num_val:]

```

Hình 14. Thực hiện việc xáo trộn và phân chia hình ảnh theo tỷ lệ

Cuối cùng, kiểm tra lại thư mục vừa mới tạo cùng với dữ liệu được sắp xếp:

```

total_images = 0
for subfolder in subfolders:
    for label in labels:
        folder_path = os.path.join(output_dataset_path, subfolder, label)
        num_images = count_images_in_folder(folder_path)
        total_images += num_images
        print(f'Thư mục đã chia {folder_path} có {num_images} hình ảnh')

print(f'Tổng số hình ảnh trong tập dữ liệu: {total_images}')

```

```

Thư mục đã chia /kaggle/working/chest_xray/train/NORMAL có 1106 hình ảnh
Thư mục đã chia /kaggle/working/chest_xray/train/PNEUMONIA có 2990 hình ảnh
Thư mục đã chia /kaggle/working/chest_xray/val/NORMAL có 157 hình ảnh
Thư mục đã chia /kaggle/working/chest_xray/val/PNEUMONIA có 426 hình ảnh
Thư mục đã chia /kaggle/working/chest_xray/test/NORMAL có 320 hình ảnh
Thư mục đã chia /kaggle/working/chest_xray/test/PNEUMONIA có 857 hình ảnh
Tổng số hình ảnh trong tập dữ liệu: 5856

```

Hình 15. Kiểm tra lại số lượng hình ảnh sau khi chia

4.2. Xây dựng các mô hình

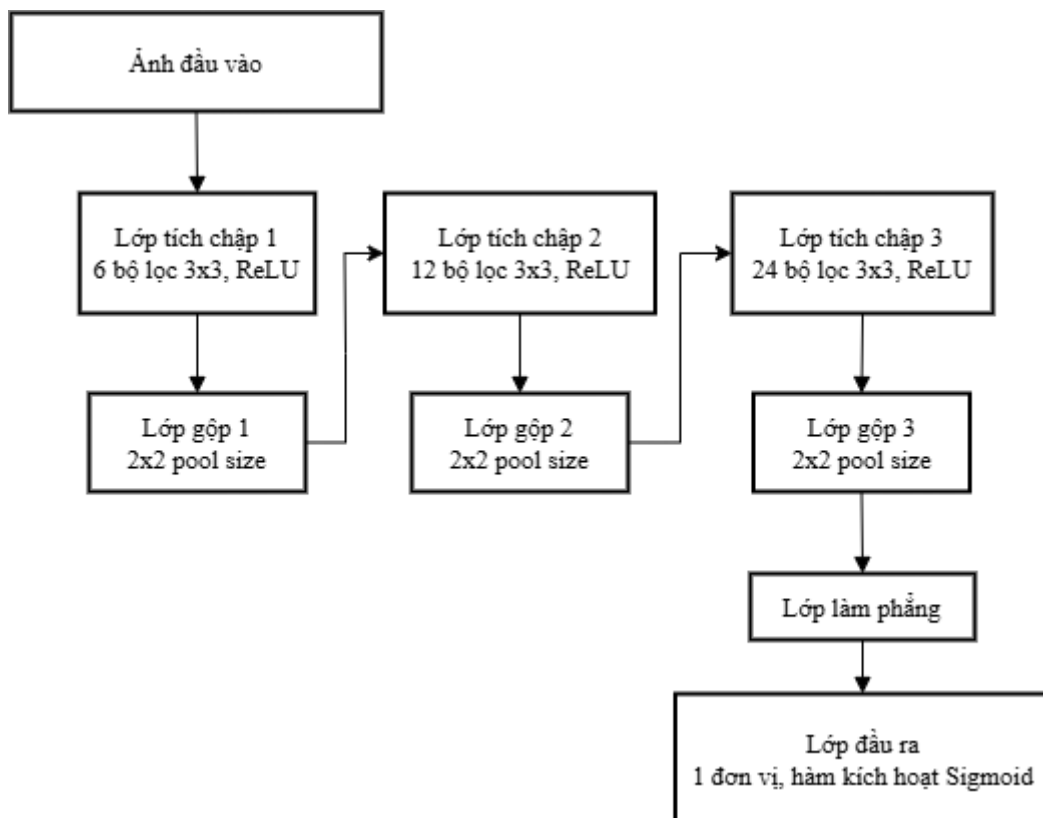
4.2.1. Mô hình CNN

Kiến trúc mô hình CNN được đề xuất như sau:

- Ảnh đầu vào với kích thước và số kênh màu của ảnh.
- Lớp tích chập 1: sử dụng 6 bộ lọc với kích thước mỗi bộ lọc là 3x3 và hàm kích hoạt ReLU. Lớp này trích xuất các đặc trưng cơ bản từ ảnh đầu vào. như cạnh và góc cạnh từ ảnh. Hàm kích hoạt ReLU giúp mô hình học các đặc trưng phi tuyến tính.
- Lớp gộp 1: sử dụng phép gộp theo giá trị lớn nhất với kích thước 2x2 để giảm kích thước và giữ lại các đặc trưng quan trọng nhất.

- Lớp tích chập 2: sử dụng 12 bộ lọc với kích thước mỗi bộ lọc là 3×3 và hàm kích hoạt ReLU. Lớp này giúp trích xuất các đặc trưng phức tạp hơn từ ảnh.
- Lớp gộp 2: sử dụng phép gộp theo giá trị lớn nhất với kích thước 2×2 để tiếp tục trích xuất và giảm kích thước các đặc trưng phức tạp hơn.
- Lớp tích chập 3: sử dụng 24 bộ lọc với kích thước bộ lọc là 3×3 và hàm kích hoạt ReLU, giúp trích xuất các đặc trưng chi tiết hơn nữa.
- Lớp gộp 3: sử dụng phép gộp theo giá trị lớn nhất với kích thước 2×2 . Lớp này tiếp tục giảm kích thước đầu ra.
- Lớp làm phẳng: biến đổi đầu ra từ lớp gộp 3 thành một vector một chiều để đưa vào lớp đầu ra.
- Lớp đầu ra: 1 đơn vị với hàm kích hoạt sigmoid để phân loại ảnh đầu vào thành bình thường hoặc bất thường dựa trên các đặc trưng đã học.

Sơ đồ khối của kiến trúc mô hình trên được minh họa như sau:



Hình 16. Sơ đồ khối kiến trúc CNN được đề xuất

Mã nguồn cho mô hình trên được trình bày như trong hình sau:

```
model_CNN = models.Sequential()
model_CNN.add(layers.Conv2D(6, (3, 3), activation='relu', input_shape=image_size + (3,)))
model_CNN.add(layers.MaxPooling2D((2, 2)))
model_CNN.add(layers.Conv2D(12, (3, 3), activation='relu'))
model_CNN.add(layers.MaxPooling2D((2, 2)))
model_CNN.add(layers.Conv2D(24, (3, 3), activation='relu'))
model_CNN.add(layers.MaxPooling2D((2, 2)))
model_CNN.add(layers.Flatten())
model_CNN.add(layers.Dense(1, activation='sigmoid'))
```

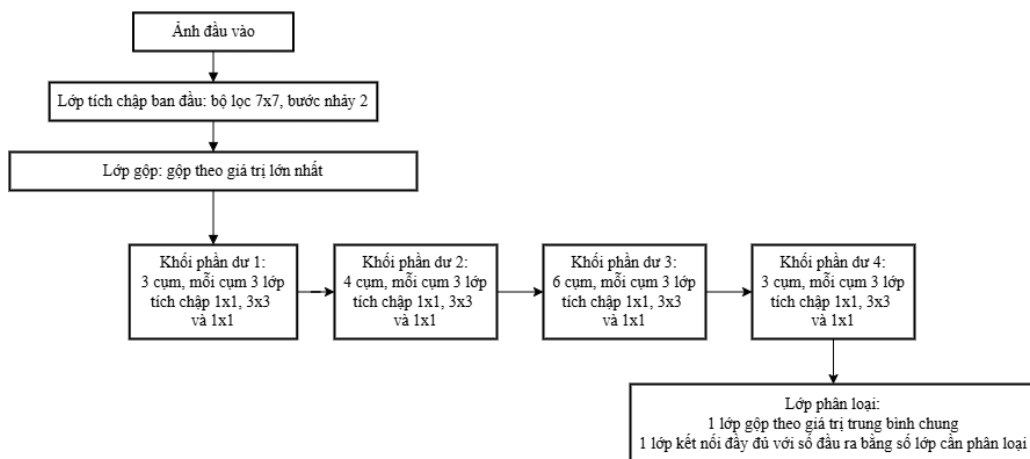
Hình 17. Mã nguồn kiến trúc mô hình CNN

4.2.2. Mô hình ResNet

Trong khoá luận này, chúng ta sử dụng biến thể ResNet50. ResNet50 có cấu trúc chính như sau:

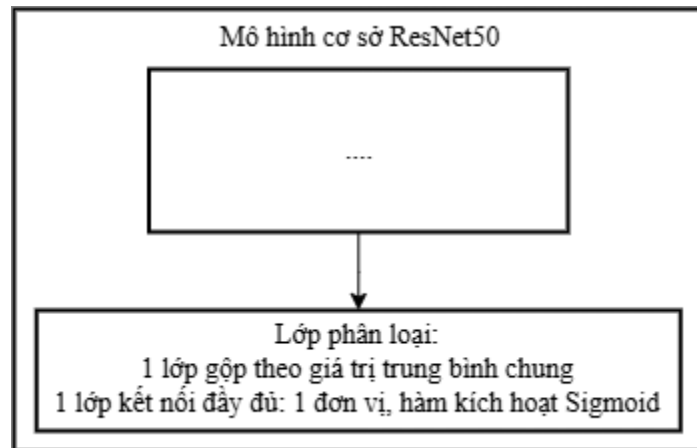
- Ảnh đầu vào với kích thước và số kênh màu của ảnh.
- Lớp tích chập ban đầu: sử dụng bộ lọc với kích thước 7x7 và bước nhảy 2.
- Lớp gộp: gộp theo giá trị lớn nhất với bộ lọc có kích thước 3x3, bước nhảy 2.
- Các khối phần dư: gồm 4 khối, mỗi khối lại gồm nhiều cụm 3 lớp tích chập có bộ lọc lần lượt là 1x1, 3x3 và 1x1.
 - o Khối phần dư 1: 3 cụm.
 - o Khối phần dư 2: 4 cụm.
 - o Khối phần dư 3: 6 cụm.
 - o Khối phần dư 4: 3 cụm.
- Lớp phân loại: Gồm một lớp gộp theo giá trị trung bình chung, tiếp theo là một lớp kết nối đầy đủ với số lượng đầu ra bằng số lớp cần phân loại.

Sơ đồ khối của biến thể ResNet50 được minh hoạ như sau:



Hình 18. Sơ đồ khối kiến trúc chung của ResNet50

Dựa vào kiến trúc của ResNet50 trên, trong kiến trúc được đề xuất chúng ta sử dụng biến thể ResNet50 đã được đề cập, sau đó thay thế lớp cuối cùng trong lớp phân loại bằng lớp đầu ra có 1 đơn vị với hàm kích hoạt là sigmoid cho bài toán phân loại nhị phân, đại diện cho hai nhãn đầu ra “bình thường” và “bất thường”. Sơ đồ khối chung của mô hình này như sau:



Hình 19. Sơ đồ khối mô hình ResNet được đề xuất

Từ đó, mã nguồn cho mô hình trên được trình bày như trong hình sau:

```

base_model = ResNet50(weights='imagenet', include_top=False)
# Thêm lớp phân loại cuối cùng
x = base_model.output
x = GlobalAveragePooling2D()(x)
predictions = Dense(1, activation='sigmoid')(x) # 2 lớp đầu ra: "bình thường" và "bất thường"
# Tạo mô hình mới
model_resnet = Model(inputs=base_model.input, outputs=predictions)
for layer in base_model.layers:
    layer.trainable = False

model_resnet.layers[-1].trainable = True
  
```

Hình 20. Mã nguồn kiến trúc mô hình ResNet

Trong hình ảnh của mã nguồn trên, ta có:

- Ảnh đầu vào với kích thước và số kênh màu của ảnh.
- Mô hình cơ sở ResNet50: được lấy từ thư viện Keras, đã được huấn luyện trước trên tập dữ liệu ImageNet.
- Lớp gộp trung bình chung: giảm kích thước của hình ảnh xuống còn một vector duy nhất cho mỗi kênh màu.
- Lớp đầu ra: cũng là 1 đơn vị với hàm kích hoạt là sigmoid để phân loại.

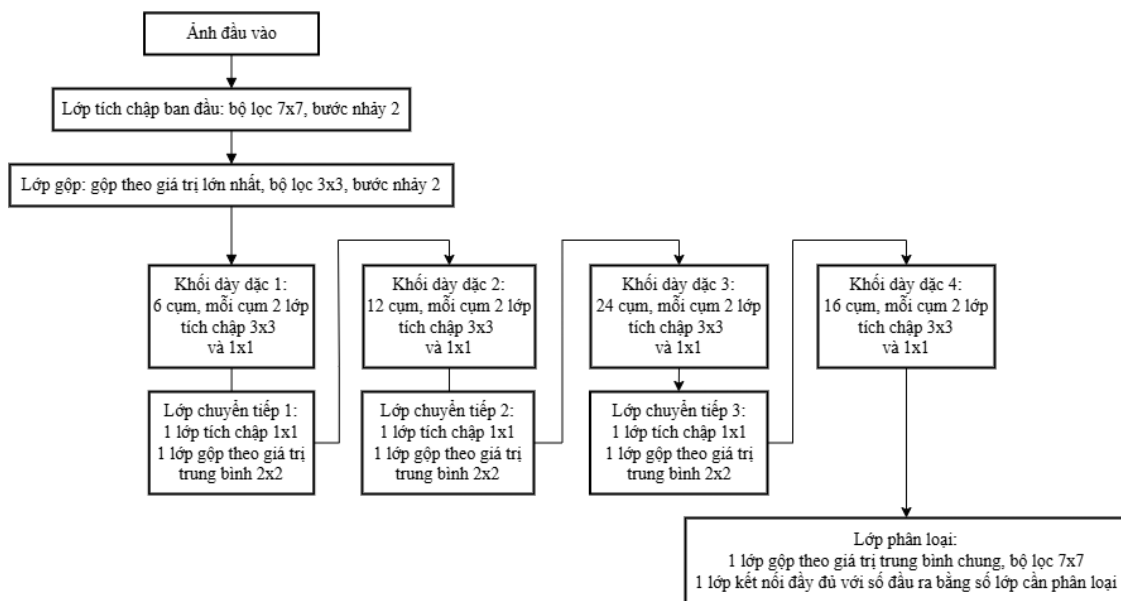
Thuật toán tối ưu hoá, hàm mất mát và chỉ số đánh giá mô hình tương tự như trong mục 3.3.1.

4.2.3. Mô hình DenseNet

Trong khoá luận này, chúng ta sử dụng biến thể DenseNet121. DenseNet121 có cấu trúc chính như sau:

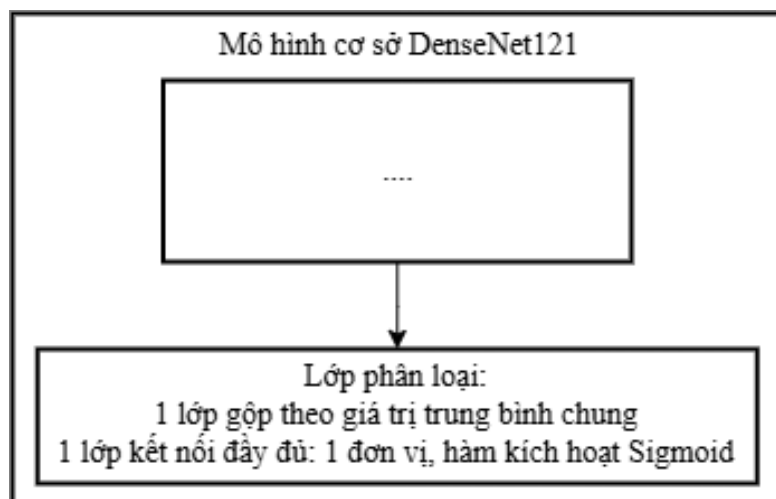
- Ảnh đầu vào với kích thước và số kênh màu của ảnh.
- Lớp tích chập ban đầu: sử dụng bộ lọc với kích thước 7×7 và bước nhảy 2.
- Lớp gộp: sử dụng phép gộp theo giá trị lớn nhất với bộ lọc có kích thước 3×3 , bước nhảy 2.
- Các khối dày đặc: gồm 4 khối, mỗi khối bao gồm nhiều cụm 2 lớp tích chập có bộ lọc 1×1 và 3×3 kế tiếp nhau
 - o Khối dày đặc 1: có 6 cụm.
 - o Khối dày đặc 2: có 12 cụm.
 - o Khối dày đặc 3: có 24 cụm.
 - o Khối dày đặc 4: có 16 cụm.
- Giữa các khối dày đặc là các lớp chuyển tiếp: gồm 3 lớp để giảm chiều kích thước không gian của đặc trưng; mỗi lớp này gồm một lớp tích chập với bộ lọc có kích thước 1×1 và một lớp gộp theo giá trị trung bình với bộ lọc có kích thước 2×2 , bước nhảy 2.
- Lớp phân loại: Gồm một lớp gộp theo giá trị trung bình chung với bộ lọc có kích thước 7×7 , tiếp theo là một lớp kết nối đầy đủ với số lượng đầu ra bằng số lớp cần phân loại.

Sơ đồ khối của biến thể DenseNet121 được minh hoạ như sau:



Hình 21. Sơ đồ khối kiến trúc chung của DenseNet121

Dựa vào kiến trúc của DenseNet121 trên, trong kiến trúc được đề xuất chúng ta sử dụng biến thể DenseNet121 đã được đề cập, sau đó cũng thay thế lớp cuối cùng trong lớp phân loại bằng lớp đầu ra có 1 đơn vị với hàm kích hoạt là sigmoid cho bài toán phân loại nhị phân, đại diện cho hai nhãn đầu ra “bình thường” và “bất thường”. Sơ đồ khối chung của mô hình này như sau:



Hình 22. Sơ đồ khối mô hình DenseNet được đề xuất

Từ đó, mã nguồn cho mô hình trên được trình bày như trong hình sau:

```
from keras.applications import DenseNet121
```

```
base_model = DenseNet121(weights='imagenet', include_top=False)
x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dense(1, activation='sigmoid')(x)

model_densenet = Model(inputs=base_model.input, outputs=x)
```

Hình 23. Mã nguồn kiến trúc mô hình DenseNet

Trong hình ảnh của mã nguồn trên, ta có:

- Ảnh đầu vào với kích thước và số kênh màu của ảnh.
- Mô hình cơ sở DenseNet121: cũng được lấy từ thư viện Keras và đã được huấn luyện trước trên tập dữ liệu ImageNet.
- Lớp gộp trung bình chung: tương tự ResNet, giảm kích thước của hình ảnh xuống một vector duy nhất tạo ra một đầu ra.
- Lớp đầu ra: cũng với 1 đơn vị và hàm kích hoạt sigmoid.

4.3. Huấn luyện các mô hình

Trong khoá luận này, các tham số chính được sử dụng trong quá trình huấn luyện các mô hình là tương tự nhau, bao gồm:

- Thuật toán tối ưu hoá: Adam
- Learning rate: 0.001
- Số lần học (epochs): 50
- Hàm mất mát: binary_crossentropy (do bài toán là phân loại nhị phân)
- Chỉ số đánh giá: Accuracy

Tập đánh giá val_ds được sử dụng để điều chỉnh các trọng số của mô hình thông qua quá trình lan truyền ngược và tối ưu hóa.

4.4. Đánh giá các mô hình

Các mô hình được đánh giá bằng cách sử dụng chỉ số độ chính xác (accuracy) là tỷ lệ dự đoán đúng trên tổng số mẫu kiểm tra, và ma trận nhầm lẫn (confusion matrix) để biểu thị số lượng dự đoán đúng và sai của mô hình trong các lớp khác nhau.

```
loss, accuracy = model_CNN.evaluate(test_ds)
print(f'Test loss: {loss}, Test accuracy: {accuracy}')
```

19/19 ————— 4s 211ms/step - accuracy: 0.9407 - loss: 0.2264
Test loss: 0.3050755560398102, Test accuracy: 0.9405267834663391

Hình 24. Chỉ số độ chính xác trên tập kiểm thử của mô hình CNN

Kết quả đánh giá của mô hình CNN trên tập dữ liệu kiểm tra cho thấy mức độ chính xác đạt 94.07% và giá trị độ mất mát là 22.64%. Điều này chứng tỏ mô hình CNN đã học được các đặc trưng của dữ liệu và có khả năng phân loại tốt. Tuy nhiên, giá trị mất mát vẫn còn khá cao so với độ chính xác, có thể do mô hình chưa tối ưu hóa hoàn toàn hoặc dữ liệu kiểm tra có một số mẫu khó phân loại. Việc cải thiện có thể bao gồm việc tối ưu hóa các tham số, thêm các tầng mạng phức tạp hơn, hoặc sử dụng các kỹ thuật tăng cường dữ liệu để nâng cao hiệu quả của mô hình.

```
loss, accuracy = model_resnet.evaluate(test_ds)
print(f'Test loss: {loss}, Test accuracy: {accuracy}')
```

19/19 ————— 9s 472ms/step - accuracy: 0.9545 - loss: 0.1206
Test loss: 0.11202114820480347, Test accuracy: 0.9549702405929565

Hình 25. Chỉ số độ chính xác trên tập kiểm thử của mô hình ResNet

Mô hình ResNet đạt được độ chính xác 95.45% trên tập dữ liệu kiểm tra, với giá trị độ mất mát là 12.06%. Kết quả này cho thấy ResNet hoạt động tốt hơn mô hình CNN thông thường, nhờ vào kiến trúc sâu và các cơ chế kết nối tắt giúp tránh hiện tượng mất mát thông tin trong quá trình huấn luyện. Giá trị mất mát thấp cho thấy mô hình đã tối ưu hóa tốt, giảm thiểu lỗi và khả năng tổng quát hóa cao hơn. Tuy nhiên, thời gian chạy của mô hình này cũng dài hơn so với CNN, cho thấy sự phức tạp trong việc xử lý và tính toán.

```
loss, accuracy = model_densenet.evaluate(test_ds)
print(f'Test loss: {loss}, Test accuracy: {accuracy}')
```

19/19 ————— 17s 942ms/step - accuracy: 0.9758 - loss: 0.2022
Test loss: 0.14186137914657593, Test accuracy: 0.9787595868110657

Hình 26. Chỉ số độ chính xác trên tập kiểm thử của mô hình DenseNet

Mô hình DenseNet cho kết quả rất ấn tượng với độ chính xác 97.58% và giá trị độ mất mát chỉ ở mức 20.22%. Mặc dù thời gian chạy dài hơn so với các mô hình khác, nhưng hiệu quả phân loại cao của DenseNet cho thấy đây là một lựa chọn tối ưu cho việc xử lý các bài toán phân loại phức tạp. Tuy nhiên, mô hình này có thời gian xử lý lâu hơn và không tối ưu hơn so với hai mô hình kia.


Tiếp theo, có thể trực quan hoá các độ chính xác của các mô hình trên hai tập huấn luyện và đánh giá như trong hình sau:

```
def plot_hist(history):
    plt.figure(figsize=(12, 6))
    plt.plot(history.history["accuracy"], label='train')
    plt.plot(history.history["val_accuracy"], label='validation')
    plt.title("Độ chính xác của mô hình")
    plt.ylabel("accuracy")
    plt.xlabel("epoch")
    plt.legend()
    plt.show()
```

Hình 27. Hàm vẽ biểu đồ thể hiện độ chính xác khi huấn luyện của các mô hình


Sau đó, chúng ta trực quan hoá kết quả huấn luyện bằng các biểu đồ minh họa độ chính xác và độ mất mát của mô hình qua các lần huấn luyện, mỗi biểu đồ có hai đường tương ứng cho hai tập huấn luyện và đánh giá. Sự hội tụ của các đường này sẽ chỉ ra độ ổn định của hiệu suất mô hình.

```
plot_hist(hist_CNN)
```



Hình 28. Biểu đồ thể hiện độ chính xác khi huấn luyện mô hình CNN

Biểu đồ trên cho thấy mô hình CNN đã cải thiện độ chính xác từ lần đầu tiên đến khoảng lần thứ 10. Từ đó trở đi, độ chính xác trên tập huấn luyện tiếp tục tăng và đạt mức tối đa ở các lần thứ 24 – 28, trong khi độ chính xác trên tập đánh giá dao động xung quanh mức 0.95 và cao nhất đạt ở lần thứ 10.



Hình 29. Biểu đồ thể hiện độ mất mát khi huấn luyện mô hình CNN


Độ mất mát của mô hình giảm đáng kể từ lần đầu tiên đến khoảng lần thứ 10, từ mức rất cao xuống mức thấp hơn. Tuy nhiên, từ lần thứ 10 trở đi, độ mất mát trên tập đánh giá có xu hướng tăng nhẹ, cho thấy mô hình bắt đầu quá khớp với dữ liệu huấn luyện. Ở lần cuối cùng, độ mất mát trên tập đánh giá đạt mức cao hơn so với các lần trước đó, trong

khi độ mất mát trên tập huấn luyện rất thấp, cho thấy mô hình đã học tốt trên tập huấn luyện nhưng có thể không tổng quát hóa tốt trên dữ liệu mới.

Mô hình CNN đã học và cải thiện độ chính xác một cách đáng kể trong quá trình huấn luyện. Mặc dù hiện tượng quá khớp xảy ra, độ chính xác trên tập dữ liệu đánh giá vẫn giữ ở mức cao, cho thấy mô hình có khả năng phân loại tốt trên tập dữ liệu đánh giá. Tuy nhiên, để cải thiện mô hình hơn nữa, cần xem xét các kỹ thuật như điều chỉnh siêu tham số, sử dụng các lớp loại bỏ, hoặc tăng cường dữ liệu để giảm thiểu hiện tượng quá khớp và cải thiện độ chính xác trên dữ liệu mới.


Đến với mô hình ResNet, quá trình huấn luyện thu được biểu đồ như sau:

```
plot_hist(hist_resnet)
```



Hình 30. Biểu đồ thể hiện độ chính xác khi huấn luyện mô hình ResNet

Trong biểu đồ trên, có thể thấy rằng độ chính xác của mô hình trên cả hai tập dữ liệu đều tăng dần qua các lần huấn luyện. Độ chính xác của mô hình trên tập huấn luyện tăng dần qua mỗi lần huấn luyện, bắt đầu từ khoảng 78% ở lần đầu tiên và tăng đều đến 99% đến lần thứ 50. Tuy nhiên, độ chính xác trên tập đánh giá chỉ tăng nhẹ từ 93% lên 96% và có vẻ như đã bão hòa sau khoảng 20 lần huấn luyện. Do đó, tuy cả hai giá trị đều ở mức tốt thể hiện mức độ nhất quán cao giữa kết quả trên tập huấn luyện và tập đánh giá, nhưng mô hình cho thấy sự quá khớp khi huấn luyện. Mô hình có thể đã học đủ từ dữ liệu và có thể không cần huấn luyện thêm nhiều lần để cải thiện nữa.



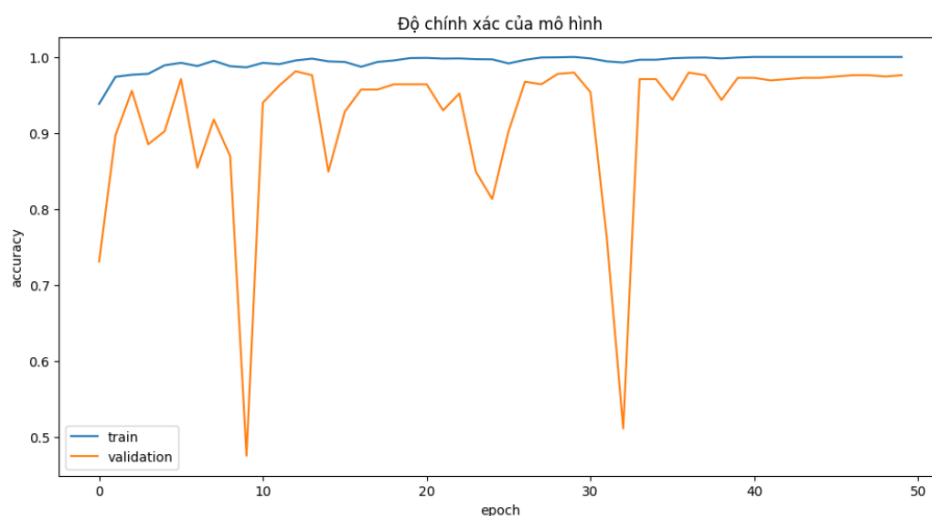
Hình 31. Biểu đồ thể hiện độ mất mát khi huấn luyện mô hình ResNet

Biểu đồ mất mát cho thấy mất mát giảm dần qua thời gian, bắt đầu từ hơn 30% ở lần đầu tiên và giảm xuống còn khoảng 3% ở lần cuối cùng trên tập huấn luyện. Điều này cho thấy mô hình đang học hỏi từ dữ liệu và cải thiện hiệu suất của nó. Tuy nhiên, mất mát trên tập đánh giá không giảm mạnh như vậy và có vẻ như đã bão hòa sau khoảng 25 lần huấn luyện, chỉ giảm từ khoảng 18% xuống còn khoảng 10%.

Mô hình ResNet đã học tốt và đạt được hiệu suất cao trên cả tập huấn luyện và tập kiểm thử. Tuy nhiên, có thể cần phải điều chỉnh thêm để ngăn chặn hiện tượng quá khớp và cải thiện hiệu suất trên tập đánh giá.

Tiếp theo, biểu đồ sau đây thể hiện độ chính xác khi huấn luyện mô hình DenseNet:

```
plot_hist(hist_densenet)
```



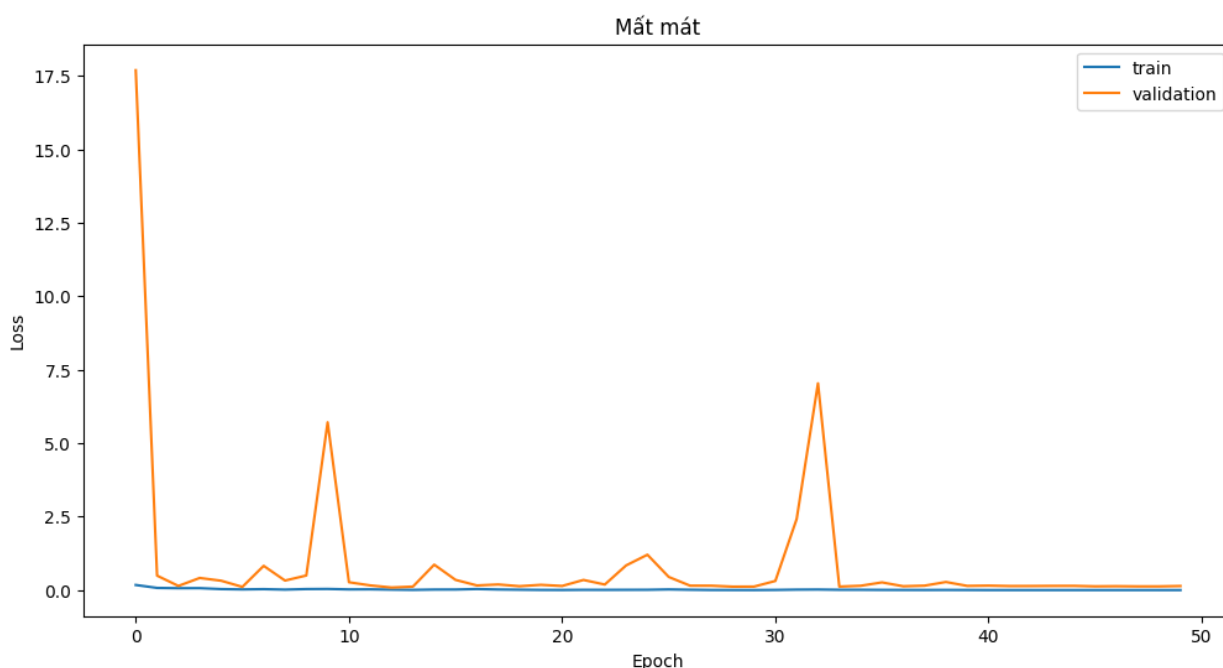
Hình 32. Biểu đồ thể hiện độ chính xác khi huấn luyện mô hình DenseNet

Có thể thấy rằng độ chính xác của mô hình trên cả hai tập dữ liệu đều tăng dần qua các lần huấn luyện. Độ chính xác của mô hình trên tập huấn luyện tăng đều dần bắt đầu từ khoảng 93% ở lần đầu tiên và đạt đến 100% ở lần cuối cùng. Điều này cho thấy mô hình đang học và cải thiện hiệu suất của nó trên tập huấn luyện.

Tuy nhiên, độ chính xác trên tập đánh giá chỉ tăng từ khoảng 73% lên khoảng 97% và có những biến động lớn trong quá trình huấn luyện. Từ lần thứ 3 trở đi, mặc dù có một số giai đoạn mô hình đạt độ chính xác cao trên tập đánh giá (như ở lần thứ 6), nhưng nhìn chung mô hình không duy trì được sự ổn định trên tập đánh giá. Đến các lần sau, mô hình tiếp tục đạt độ chính xác rất cao trên tập huấn luyện gần như tuyệt đối, trong khi độ chính xác trên tập xác thực không ổn định và có những giai đoạn giảm mạnh.

Do vậy, có thể thấy mô hình đang bị quá khớp với dữ liệu huấn luyện, dẫn đến việc nó không thể tổng quát hóa tốt trên tập dữ liệu đánh giá. Điều này được minh chứng qua độ chính xác rất cao trên tập huấn luyện và độ chính xác dao động mạnh trên tập đánh giá.

Cuối cùng, biểu đồ sau thể hiện độ mất mát khi huấn luyện mô hình DenseNet:



Hình 33. Biểu đồ thể hiện độ mất mát khi huấn luyện mô hình DenseNet

Biểu đồ mất mát cho thấy mất mát giảm dần qua thời gian, bắt đầu từ khoảng hơn 0.5% ở lần đầu tiên và giảm xuống còn gần như bằng 0% ở lần cuối cùng trên tập huấn luyện. Điều này cho thấy mô hình đang học hỏi từ dữ liệu và cải thiện hiệu suất của nó. Tuy nhiên, độ mất mát trên tập kiểm thử có xu hướng dao động rất mạnh và có những giá

trị rất cao trong một số lần huấn luyện. Điều này cho thấy mô hình đang gặp khó khăn trong việc học từ dữ liệu xác thực và có thể dự báo không tốt.

Mô hình DenseNet đã học tốt và đạt được hiệu suất cao trên cả tập huấn luyện và tập kiểm thử. Tuy nhiên, có thể cần phải điều chỉnh thêm để ngăn chặn hiện tượng quá khớp và cải thiện hiệu suất trên tập đánh giá.

Tiếp theo, chúng ta sẽ sử dụng ma trận nhầm lẫn để đánh giá các hiệu suất của các mô hình. Ma trận nhầm lẫn là một công cụ hữu ích cung cấp cái nhìn chi tiết về số lượng dự đoán đúng và sai của mô hình trong các lớp khác nhau, giúp hiểu rõ hơn về hiệu quả của mô hình trong việc phân biệt giữa các lớp.

Cấu trúc của ma trận bao gồm bốn giá trị chính: True Positive (TP), True Negative (TN), False Positive (FP), và False Negative (FN). Các giá trị này của ma trận nhầm lẫn được trình bày như sau:


		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

Hình 34. Ma trận nhầm lẫn [22]

Trong hình trên, ta lần lượt có các giá trị:

- TP – True Positive: là số lượng các trường hợp mà mô hình dự đoán chính xác mẫu thuộc lớp Positive; trong bài toán này nghĩa là cả mô hình và thực tế đều khẳng định rằng mẫu thuộc lớp "Normal".
- TN – True Negative: là số lượng các trường hợp mà mô hình dự đoán chính xác mẫu thuộc lớp Negative; trong bài toán này nghĩa là mô hình và thực tế đều khẳng định rằng mẫu thuộc lớp "Pneumonia".

- FP – False Positive : là số lượng các trường hợp mà mô hình dự đoán sai mẫu là thuộc lớp dương tính trong khi thực tế mẫu thuộc lớp âm tính; trong bài toán này nghĩa là mô hình đã dự đoán nhầm các mẫu "Normal" thành "Pneumonia".
 - FN – False Negative: là số lượng các trường hợp mà mô hình dự đoán sai mẫu là thuộc lớp âm tính trong khi thực tế mẫu thuộc lớp dương tính; trong bài toán này nghĩa là các mẫu "Pneumonia" bị mô hình dự đoán nhầm thành "Normal".
- Với mô hình CNN, ma trận nhầm lẫn của nó như sau:



Hình 35. Ma trận nhầm lẫn của mô hình CNN

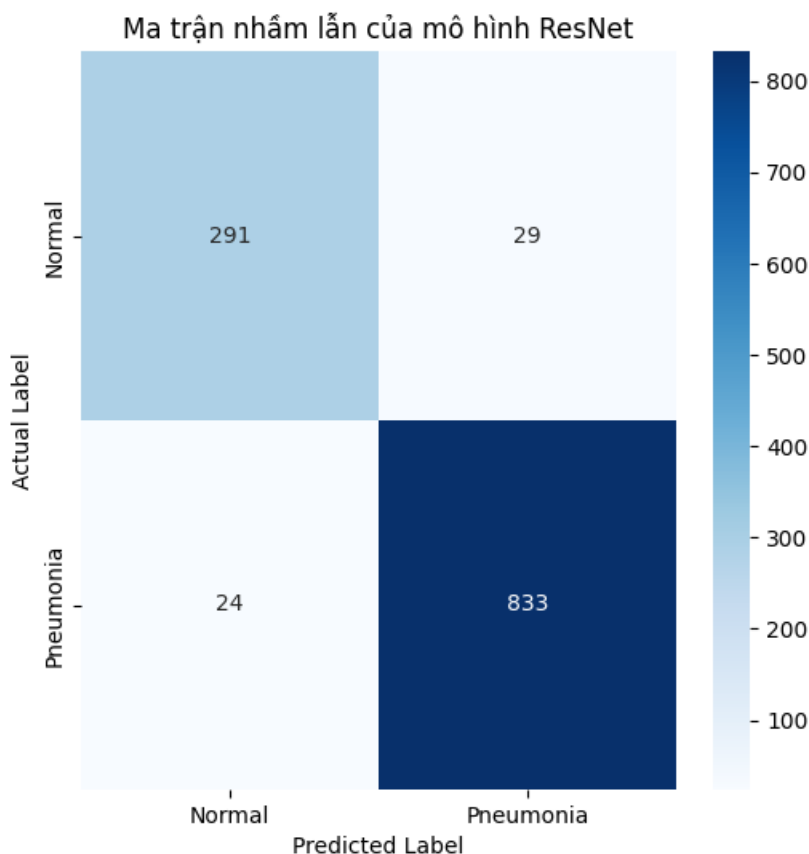
Từ ma trận này, có thể nhận thấy mô hình CNN có khả năng phân loại tốt với mức độ chính xác khá cao, mặc dù vẫn còn tồn tại một số sai sót trong việc phân biệt giữa các lớp.

Ma trận nhầm lẫn của mô hình CNN cho thấy rằng mô hình đã dự đoán đúng 287 trường hợp thuộc lớp Normal và 821 trường hợp thuộc lớp Pneumonia. Số lượng mẫu False Positive và False Negative tương ứng là 33 và 36, tức là có 33 trường hợp mà mô hình đã

dự đoán sai là dương tính trong khi thực tế là âm tính, và 36 trường hợp dự đoán sai là âm tính nhưng thực tế là dương tính.

Từ các số liệu này, có thể thấy CNN có độ chính xác khá tốt trong việc phân loại hình ảnh, mặc dù vẫn còn tồn tại một số sai sót trong việc phân biệt giữa các lớp. Do đó mô hình CNN thường ít chính xác hơn và có xu hướng mắc nhiều sai sót hơn.

Tiếp theo, kiểm thử mô hình ResNet cho ra ma trận nhầm lẫn như sau:




Hình 36. Ma trận nhầm lẫn của mô hình ResNet

Với ResNet, ma trận nhầm lẫn đầu tiên cho thấy số lượng True Positive là 291 và True Negative là 833. So với CNN, Đây là một sự cải thiện so với CNN, với số lượng dự đoán đúng nhiều hơn, cho thấy mô hình này có độ chính xác cao hơn trong việc phân loại đúng các trường hợp. Tuy nhiên, có 29 mẫu "Normal" bị phân loại nhầm thành "Pneumonia" và 24 mẫu "Pneumonia" bị phân loại sai thành "Normal". Mặc dù vậy, số lượng này thấp hơn so với CNN, cho thấy ResNet có khả năng giảm thiểu sai sót hơn.

Kết quả này chỉ ra rằng ResNet có khả năng phân biệt giữa các lớp một cách hiệu quả hơn, đặc biệt là trong việc giảm thiểu các dự đoán sai.

Cuối cùng, ma trận nhầm lẫn cho DenseNet được thể hiện như sau:



Hình 37. Ma trận nhầm lẫn của mô hình DenseNet

Mô hình DenseNet cho thấy sự cải thiện đáng kể khi đạt được số lượng True Positive là 301 và True Negative là 848, khiến nó trở thành mô hình có độ chính xác cao nhất trong ba mô hình đã thử nghiệm. Số lượng False Positive chỉ là 19 và False Negative là 9, phản ánh rằng DenseNet có tỷ lệ lỗi rất thấp.

Những con số này cho thấy DenseNet không chỉ có khả năng phân loại chính xác mà còn rất tốt trong việc tránh các dự đoán sai. Tổng thể, DenseNet đã thể hiện hiệu suất vượt trội hơn so với CNN và ResNet, với số lượng dự đoán đúng cao hơn và ít sai sót hơn. Điều này cho thấy DenseNet có khả năng học và tổng quát hóa tốt hơn, giúp cải thiện hiệu quả của hệ thống phân loại hình ảnh.

Dựa trên các kết quả về độ chính xác và ma trận nhầm lẫn đã được trình bày như trên, có thể thấy rằng mô hình ResNet có hiệu quả hơn cả trong việc phân loại hình ảnh giữa các lớp "Normal" và "Pneumonia". Ở chỉ số độ chính xác, mặc dù độ chính xác của ResNet thấp hơn một chút so với DenseNet và thời gian xử lý cũng chậm hơn một chút so với CNN, nhưng mô hình này lại có ưu điểm vượt trội về yêu cầu sự cân bằng giữa hiệu

quả phân loại và tốc độ xử lý, trong khi DenseNet gặp vấn đề lớn về hiện tượng quá khớp ở tập huấn luyện và CNN gặp nhiều sai sót. Ở chỉ số ma trận nhầm lẫn, mặc dù số lượng sai sót của mô hình ResNet cao hơn một chút so với DenseNet, nhưng hiệu suất tổng thể của nó vẫn cao và có khả năng phân biệt các lớp một cách chính xác. Đặc biệt, mô hình ResNet có số lượng mẫu "Pneumonia" bị phân loại nhầm thành "Normal" thấp hơn so với mô hình CNN. Do đó, mô hình ResNet được đánh giá là lựa chọn tốt nhất cho ứng dụng này, đảm bảo tính chính xác, hiệu quả thời gian nhanh và độ tin cậy trong chẩn đoán hình ảnh.

4.5. Xây dựng giao diện phát hiện bất thường trong ảnh

Để thực hiện việc kiểm thử độ hiệu quả của mô hình, khoá luận sử dụng Flask để xây dựng hệ thống đơn giản trực quan. Người dùng đưa hình ảnh lên hệ thống, sau đó hình ảnh sẽ được xử lý và dự đoán thông qua các mô hình đã được huấn luyện sẵn, và cuối cùng hệ thống sẽ đưa ra nhãn bình thường hoặc bất thường cho hình ảnh đầu vào đó.

Cấu trúc thư mục hệ thống như sau:



Hình 38. Các thư mục của hệ thống

- .env: thư mục môi trường ảo, chứa các thư viện và cấu hình để chạy ứng dụng
- .vscode: thiết lập cài đặt cho trình biên dịch của Python
- models: thư mục chứa các tệp mô hình đã được huấn luyện
- static: thư mục chứa các tệp tin phương tiện do người dùng tải lên hoặc để kiểm thử
- templates: thư mục chứa tệp tin giao diện dưới dạng html

Ngoài ra, tệp app.py khởi động giao diện của hệ thống và xử lý việc dự đoán nhãn từ hình ảnh người dùng tải lên.

Giao diện của hệ thống có dạng:

Nhận dạng hình ảnh

Chọn hình ảnh

Choose File

No file chosen



Preview Image

Dự đoán

Hình 39. Giao diện chính

Sau đó chúng ta thực hiện tải hình ảnh lên. Chúng ta sẽ chọn mô hình ResNet để làm mô hình kiểm thử của hệ thống.

Với hình ảnh bình thường:

Nhận dạng hình ảnh

Chọn hình ảnh

Choose File

No file chosen



NORMAL2-IM-0313-0001.jpeg

Dự đoán

Kết quả dự đoán:

ResNet: NORMAL

Hình 40. Kết quả hiển thị ảnh bình thường

Với hình ảnh bất thường:

Nhận dạng hình ảnh

Chọn hình ảnh

Choose File person19_virus_50.jpeg



person19_virus_50.jpeg

Dự đoán

Kết quả dự đoán:

ResNet: PNEUMONIA

Hình 41. Kết quả hiển thị ảnh bất thường

4.6. Nhận xét

Kết quả đánh giá cho thấy các mô hình đạt độ chính xác cao, chứng minh tính hiệu quả của mô hình trong việc phát hiện bất thường trong ảnh y khoa.

CNN là mô hình đơn giản hơn, nhưng không đủ mạnh để cạnh tranh với các mô hình sâu hơn như ResNet và DenseNet. DenseNet có khả năng tái sử dụng các đặc trưng từ các lớp trước, giúp cải thiện độ chính xác, nhưng gặp vấn đề lớn với hiện tượng quá khớp. Mô hình ResNet thể hiện tính ổn định và hiệu quả cao hơn so với hai mô hình còn lại, với sự kết hợp giữa độ chính xác cao và độ hiệu quả về thời gian xử lý, do đó ResNet được xem là tốt nhất trong ba mô hình trên.

Tuy nhiên, các mô hình trên vẫn còn một số hạn chế nhất định, nhất là hiện tượng quá khớp xảy ra đáng kể trên mô hình DenseNet. Điều này khiến cho chúng gặp trở ngại lớn khi tổng quát hoá trên tập dữ liệu đánh giá, gây khó khăn cho việc phát hiện hình ảnh bất thường nếu có hình ảnh mới đưa vào. Cần xem xét và cải tiến cho các mô hình trên để cải thiện hiệu suất và giảm thiểu hiện tượng quá khớp.

4.7. Hướng dẫn sử dụng ứng dụng


Bước 1: Cài Python phiên bản 3.9.11

Tải về tại: <https://www.python.org/downloads/release/python-3911/>

Files					
Version	Operating System	Description	MD5 Sum	File Size	GPG
Gzipped source tarball	Source release		daca49063ced330eb933a0fb437dee50	25.1 MB	SIG
XZ compressed source tarball	Source release		3c8dde3ebd6da005e969b83b5f0c1886	18.8 MB	SIG
macOS 64-bit Intel-only installer	macOS	for macOS 10.9 and later, deprecated	99e519a1e8387f692da6c5a0e6177243	29.5 MB	SIG
macOS 64-bit universal2 installer	macOS	for macOS 10.9 and later	655c5ca728aafc5f64f74b94397593ad	37.0 MB	SIG
Windows installer (64-bit)	Windows	Recommended	fef52176a572efd48b7148f006b25801	27.8 MB	SIG
Windows installer (32-bit)	Windows		4210652b14a030517046cdf111c09c1e	26.7 MB	SIG
Windows help file	Windows		dbc3c10a40ebccc1d0b47616a2d4503f	8.5 MB	SIG
Windows embeddable package (64-bit)	Windows		9bc1e9dd44c1c1c68838e5b4ce9f2248	8.1 MB	SIG
Windows embeddable package (32-bit)	Windows		b5c293e11564f11cb23f9c4e4e97cbf8	7.3 MB	SIG

Hình 42. Vị trí tệp Python cần tải

Bước 2: Mở thư mục chứa ứng dụng lên bằng ứng dụng Visual Studio Code (hoặc Command Prompt)



Hình 43. Cấu trúc thư mục của ứng dụng

Bước 3: Mở cửa sổ dòng lệnh (terminal) lên, gõ lệnh:

`.\.venv\Scripts\activate`

Lệnh này để kích hoạt môi trường ảo nhằm cài đặt các thư viện riêng biệt tránh xung đột.

```
PS C:\Users\ADMIN\KhoaLuanTotNghiep\GiaoDien> .\.venv\Scripts\activate
(.venv) PS C:\Users\ADMIN\KhoaLuanTotNghiep\GiaoDien>
```

Hình 44. Kích hoạt môi trường ảo

Bước 4: Chạy ứng dụng bằng câu lệnh:

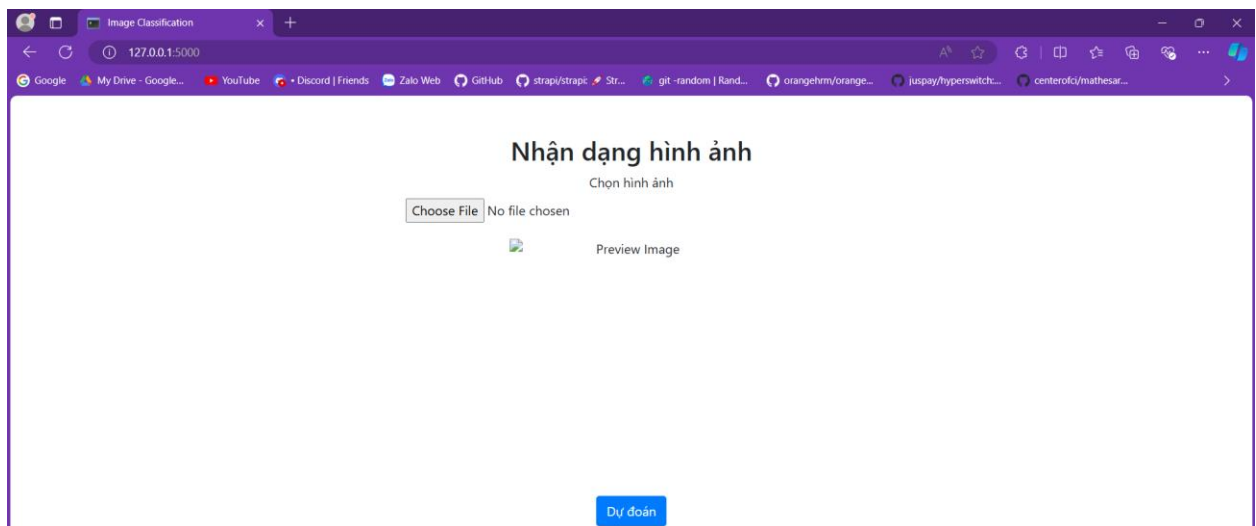
`python app.py`

Khi đó màn hình cửa sổ dòng lệnh hiển thị:

```
* Serving Flask app 'app'
* Debug mode: on
INFO:werkzeug:WARNING: This is a development server. Do not use it in a production deployment. Use a production WSGI server instead.
* Running on http://127.0.0.1:5000
INFO:werkzeug:Press CTRL+C to quit
INFO:werkzeug: * Restarting with stat
```

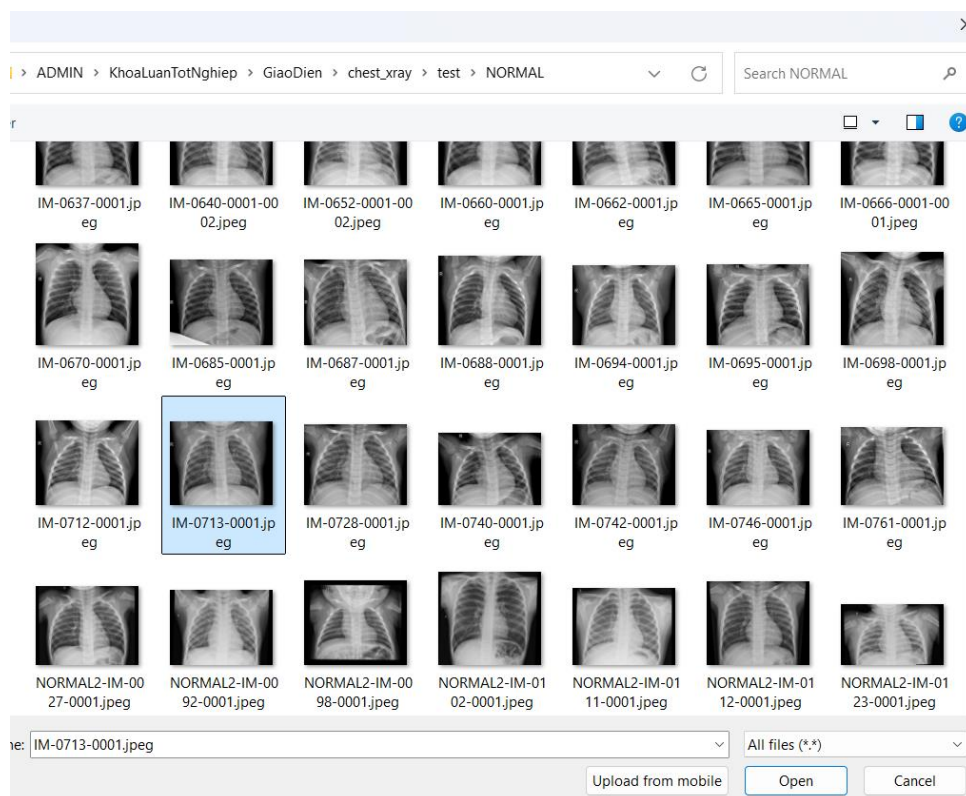
Hình 45. Thông báo chạy giao diện ứng dụng

Bước 5: Mở trình duyệt web lên, sao chép địa chỉ `http://127.0.0.1:5000` vào thanh địa chỉ và nhấn Enter (Hoặc giữ phím Ctrl và nhấn chuột trái trực tiếp vào địa chỉ đó trong cửa sổ dòng lệnh). Màn hình trình duyệt có dạng:



Hình 46. Giao diện ứng dụng trên trình duyệt

Bước 6: Nhấn chuột trái vào nút Choose File và chọn tệp hình ảnh tải lên




Hình 47. Chọn tệp hình ảnh cần thử

Kết quả sau khi chọn:

Nhận dạng hình ảnh

Chọn hình ảnh

Choose File IM-0713-0001.jpeg



IM-0713-0001.jpeg

Dự đoán


Hình 48. Kết quả sau khi tải hình ảnh lên

Bước 7: Sau khi hình ảnh được tải lên, nhấn chuột vào nút “Dự đoán”. Kết quả dự đoán sẽ được hiển thị trên màn hình

Nhận dạng hình ảnh

Chọn hình ảnh

Choose File No file chosen



IM-0713-0001.jpeg

Dự đoán

Kết quả dự đoán:

ResNet: NORMAL

Hình 49. Kết quả nhận dạng “bình thường”

Bước 8: Lặp lại các bước 6, 7 nếu muốn thử với các hình khác

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Khóa luận đã thành công trong việc phát triển và ứng dụng các mô hình học sâu để phát hiện bất thường trong ảnh y khoa. Các mô hình đã được huấn luyện và đánh giá trên bộ dữ liệu cho thấy hiệu suất cao. Kết quả này chứng tỏ rằng các mô hình học sâu được đề xuất có khả năng phân loại chính xác các ảnh bình thường và bất thường. Trong đó, ResNet được đánh giá là mô hình lý tưởng nhất, nổi bật nhờ vào sự cân bằng giữa độ chính xác cao và thời gian xử lý hợp lý.

5.2. Hướng phát triển

Để cải thiện và mở rộng các kết quả đã đạt được, các hướng phát triển có thể được xem xét như:

- Nghiên cứu và tích hợp thêm các mô hình học tăng cường để cải thiện khả năng tự học và hiệu suất của mô hình nếu đối mặt với dữ liệu chưa từng thấy trước đó.
- Mở rộng nghiên cứu sang các loại dữ liệu hình ảnh y khoa khác như hình ảnh MRI hoặc siêu âm để kiểm tra và nâng cao khả năng tổng quát hóa và độ tin cậy của mô hình.
- Xây dựng và phát triển một hệ thống cho phép kiểm tra các ảnh y khoa một cách tiện lợi, và bổ sung các tính năng mới cho hệ thống, như chẩn đoán tự động và phân tích xu hướng theo thời gian, để hỗ trợ tốt hơn cho các quyết định lâm sàng.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] Y. B. Y. & H. G. LeCun, "Deep Learning," *Nature*, tập 521, số 7553, pp. 436-444, 2015.
- [2] G. E. O. S. & T. Y. W. Hinton, "A fast learning algorithm for deep belief nets," *Neural Computation*, tập 18, số 7, pp. 1527-1554, 2006.
- [3] A. M. A.-r. & H. G. Graves, "Speech recognition with deep recurrent neural networks," in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing*, 2013.
- [4] A. S. I. & H. G. E. Krizhevsky, "Imagenet classification with deep convolutional neural networks," trong *Advances in Neural Information Processing Systems*, 2012.
- [5] "CS231n Convolutional Neural Networks for Visual Recognition," [Trực tuyến]. Available: <https://cs231n.github.io/neural-networks-1/>. [Đã truy cập 10 June 2024].
- [6] I. Sarker, "Deep Learning: a Comprehensive Overview on Techniques, Taxonomy, Applications and Research Directions," *SN Computer Science*, tập 2, số 6, 2021.
- [7] G. X. & B. Y., "Understanding the difficulty of training deep feedforward neural networks," trong *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, 2010.
- [8] R. K. R. K. O. & M. A. Bouthina, "Palm Tree Diseases Detection Using Deep Learning: A Short Review," pp. 1-8, 2024.
- [9] C. Olah, "Understanding LSTM Networks," [Trực tuyến]. Available: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>. [Đã truy cập 30 May 2024].
- [10] R. M. Schmidt, "Recurrent Neural Networks (RNNs): A gentle Introduction and Overview," 2019. [Trực tuyến]. Available: <https://arxiv.org/abs/1912.05911>. [Đã truy cập 14 June 2024].
- [11] T. P. R. C. R. Z. S. L. Y. & C. R.-C. Toharudin, "Employing Long Short-Term Memory and Facebook Prophet Model in Air Temperature Forecasting," *Communication in Statistics- Simulation and Computation*, 2021.

- [12] B. e. a. Zong, “Deep Autoencoding Gaussian Mixture Model for Unsupervised Anomaly Detection,” 2018. [Trực tuyến]. Available: <https://openreview.net/forum?id=BJJLHbb0->. [Đã truy cập 19 June 2024].
- [13] Y. H. S. & C. Y.-G. Song, “Analysis of Autoencoders for Network Intrusion Detection,” *Sensors*, tập 21, p. 4294, 2021.
- [14] I. Developer, "Generative Adversarial Networks Explained," 2021. [Online]. Available: <https://developer.ibm.com/articles/generative-adversarial-networks-explained/>. [Accessed 10 June 2024].
- [15] J. Brown và Z. & R. N. Gharineiat, “CNN Based Image Classification of Malicious UAVs,” *Applied Sciences*, tập 13, p. 240, 2022.
- [16] Z. L. L. V. D. M. & K. Q. W. G. Huang, "Densely Connected Convolutional Networks," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [17] A. S. F. R. P. & S. G. Mazza, “TanDEM-X Forest Mapping using Convolutional Neural Networks,” *Remote Sensing*, tập 11, 2019.
- [18] H. & W. L. J. Abdi, “Principal component analysis,” *Wiley Interdisciplinary Reviews: Computational Statistics*, tập 2, số 4, p. 433–459, 2010.
- [19] O. M. P. & M. D. Rippel, “Modeling the Distribution of Normal Data in Pre-Trained Deep Features for Anomaly Detection,” January 2021. [Trực tuyến]. Available: <https://ieeexplore.ieee.org/abstract/document/9412109>. [Đã truy cập 17 June 2024].
- [20] D. Z. K. & G. M. Kermany, *Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images for Classification*, Mendeley Data, 2018.
- [21] P. Mooney, "Chest X-Ray Images (Pneumonia)," [Online]. Available: <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>.
- [22] “Understanding Confusion Matrix,” Towards Data Science, [Trực tuyến]. Available: <https://towardsdatascience.com/understanding-confusion-matrix-a9ad42dcfd62>. [Đã truy cập 20 June 2024].